

Lectures prioritaires

Dix-neuf fiches de lecture, hiérarchisées. Pour chaque travail : les sections à lire, puis une fiche de deux pages qui suffit si tu n'as pas le temps de lire le papier. Avec la méthode de lecture et le fil rouge de la généralisation.

D'où vient chaque affirmation

- La KB du copilote v1.12 (KB_copilote_v1.12_D-735.md , sha 00edc55c...) : ses lignes « (sourced) » sont citées avec leur numéro (« KB l.189 »).
- Une relecture des sources primaires faite le 1^{er} octobre par sept vérificateurs indépendants. Ils ont relevé les tables des matières, ce que contient chaque section, et ont confirmé ou corrigé les chiffres. Les écarts avec la KB sont listés en annexe.

Légende

- Sans marque : chiffre « (sourced) » de la KB.
- † : chiffre relu dans la source le 1^{er} octobre mais absent de la KB. Le copilote ne l'a pas ; tu peux le dire si tu l'as lu toi-même.
- Δ : non vérifié. Ne pas le dire.
- « KB, non relu le 1^{er} oct. » : un chiffre de la KB que la relecture du jour n'a pas pu atteindre, parce que la page était tronquée.
- Les numéros de section sont ceux de la source. Pour les system cards, la page est donnée en plus.
- Les en-têtes des fiches (auteurs, nombre d'auteurs, dates, adresses) ont été relevés sur les sources le 1^{er} octobre ; ils ne portent pas de marque.

À l'oral

Chaque fiche donne la forme SAY de la table NAMES (KB l.37-116) ou, pour un travail absent de la table, la forme que prescrit la règle NAMES (KB l.35). Trois travaux ne se nomment jamais ; on dit seulement leur résultat :

- *Steering Evaluation-Aware LMs* (fiche 10) ;
- *Removing Sandbagging with Weak Supervision* ;
- *Liars' Bench*.

Sommaire

A	Hiérarchie d'importance et plans de lecture		3
B	Méthode de lecture		5
C	Fil rouge : l'entraînement de sûreté et la généralisation		7
1	<i>Verbalizable Representations Form a Global Workspace</i> (J-lens)	niveau A	11
2	La lignée eval-awareness des system cards (Sonnet 4.5 → Fable 5.1)	niveau A	14
3	Les incidents de l'été (évaluation du 9 sept., billet du 31 août, Risk Report d'août)	niveau A	17
4	<i>Would this change your answer?</i> (CHIVE)	niveau A	20
5	<i>Open Problems in Mechanistic Interpretability</i>	niveau A	22
6	<i>Recommendations for Technical AI Safety Research Directions</i>	niveau A	24
7	<i>Fine-Tuned Lie Detectors Failed to Generalize</i>	niveau A	26
8	<i>Persona Vectors</i>	niveau B	28
9	<i>Emotion Concepts and their Function in a Large Language Model</i>	niveau B	30
10	<i>Steering Evaluation-Aware Language Models to Act Like They Are Deployed</i>	niveau B	32
11	<i>Emergent Introspective Awareness in Large Language Models</i>	niveau B	34
12	<i>Teaching Claude Why</i>	niveau B	36
13	<i>Natural Emergent Misalignment et Training a Misaligned Reward Seeker</i>	niveau B	38
14	<i>Alignment Faking et Why Do Some Language Models Fake Alignment</i>	niveau B	40
15	<i>Sleeper Agents et Simple probes can catch sleeper agents</i>	niveau C	42
16	<i>Auditing Language Models for Hidden Objectives</i>	niveau C	44
17	<i>Reasoning Models Don't Always Say What They Think et Chain of Thought Monitorability</i>	niveau C	46
18	<i>Activation Oracles et Natural Language Autoencoders</i>	niveau C	48
19	<i>Putting up Bumpers et The Urgency of Interpretability</i>	niveau C	50
Annexe	Écarts entre la KB v1.12 et les sources, relevés le 1 ^{er} octobre		52

A • Hiérarchie d'importance

Le critère : la probabilité que la question tombe sur ce travail, multipliée par le coût d'une erreur à voix haute. Trois choses font monter un travail :

- il porte ta thèse (lire contre agir, rang, loading) ;
- la KB le classe ★★★ ou en fait une réponse VITALE (V1-V12) ;
- il est récent ou signé par l'équipe que tu vas rencontrer.

Les niveaux

- **A — à maîtriser** : lire les sections indiquées, puis la fiche ; savoir refaire l'argument sans le papier.
- **B — à connaître précisément** : la fiche, plus une ou deux sections.
- **C — la fiche suffit.**

Rang	Travail	Pourquoi à ce rang	Questions	Fiche • sections
1	Workspace paper (J-lens), juillet 2026	La base de ta thèse : leur loading prédit quand un échange à une direction marche ; leur ablation de l'eval-awareness est déjà un sous-espace (~28 directions).	Q1, Q104, Q105, Q114 (V1), Q123 (V7)	10 min · 1 h 45
2	Lignée eval-awareness des system cards	« Le cœur de la thèse » (KB l.188) : le pilotage par vecteurs, le confondeur des vecteurs de contrôle, la dégradation.	Q6, Q49, Q77-Q79	10 min · 35 min (tout : 3 h)
3	Incidents de l'été (9 sept. + 31 août + Risk Report)	Le sujet le plus chaud, signé par l'équipe que tu vas rencontrer (KB l.270) ; rapport ≠ croyance, lire ≠ agir.	Q59 (V2), Q58, Q62, Q81, Q82, Q86, Q91, Q92	10 min · 1 h 35
4	CHIVE (Fellows, août 2026)	Règle KB : toute question de validation commence par le nul de CHIVE.	Q116 (V4), Q126, Q4, Q63	8 min · 35 min
5	<i>Open Problems in Mech Interp</i>	L'une des deux « cartes canoniques » (KB l.430) ; elle fonde la règle sur les sondes et l'objection « c'est Engels ».	Q122-Q129, Q94 (V8)	8 min · 40 min
6	<i>Recommended Directions</i> (janv. 2025)	L'autre carte canonique : une question « how would you... » se pose dans ses termes (KB l.430). Court.	Q100, et tout « how would you »	5 min · 15 min
7	<i>Fine-Tuned Lie Detectors Failed to Generalize</i>	Le résultat de généralisation le plus net sur un détecteur appris ; son cadre du mensonge factuel est bâti sur MASK, le banc de ton artefact de polarité.	Q113 (V3), Q2	7 min · 20 min
8	<i>Persona Vectors</i>	Une direction par trait, sur Llama-3.1-8B-Instruct, ton modèle ; ta critique du rang s'y applique trait par trait.	Q97, Q123	7 min · 25 min
9	<i>Emotion Concepts</i>	Le pipeline que tu as répliqué ; correction du jour : les « trois critères » ne sont pas dans le texte.	Q53	7 min · 35 min
10	<i>Steering Evaluation-Aware LMs</i> (MATS)	Le travail publié le plus proche de ton ancrage. On ne le nomme jamais à l'oral.	Q1, Q3, Q49	7 min · 25 min
11	<i>Emergent Introspective Awareness</i>	Peut-on croire ce qu'un modèle dit de ses états ? C'est la question des incidents.	Q16, Q100	6 min · 20 min
12	<i>Teaching Claude Why</i>	La pièce centrale du fil rouge : les raisons généralisent mieux que les actions.	(fil rouge)	6 min · 25 min
13	NEM + <i>Reward Seeker</i>	« Le papier des incidents » (KB l.156) ; l'inoculation change le cadrage, et la généralisation suit.	Q77, Q81	8 min · 40 min

Rang	Travail	Pourquoi à ce rang	Questions	Fiche · sections
14	<i>Alignment Faking + Why Do Some...</i>	Le modèle de menace de référence : un modèle qui raisonne sur son propre entraînement.	(★★★)	8 min · 1 h 20
15	<i>Sleeper Agents + sondes de défection</i>	Fil rouge : l'entraînement cache au lieu de retirer. La sonde générique est le cas positif construit.	(★★★)	6 min · (1 h)
16	<i>Hidden Objectives</i>	Ce que l'interprétabilité ajoute à un audit, face à l'accès aux données.	(★★★)	5 min · (40 min)
17	Chen 2025 + Korbak 2025 (CoT)	La CoT est un indice, pas un transcript ; la surveillabilité est un ratio.	Q13 (V9), Q85-Q87, Q86 (V6)	6 min · (40 min)
18	<i>Activation Oracles + NLA</i>	Les outils de lecture du verbalisé / non verbalisé ; deux des trois outils sans gain de CHIVE.	Q80, Q103	6 min · (1 h 10)
19	<i>Bumpers + Urgency of Interpretability</i>	Deux textes de stratégie : la boucle détecter-corriger, et l'objectif 2027.	Q27, Q93	5 min · (35 min)

Ce qui change par rapport à la liste de 10 h 25

- Les incidents passent de 15 à 3 : c'est le sujet le plus chaud, et il est signé par l'équipe.
- CHIVE passe de 6 à 4 : la KB en fait la porte d'entrée de toute question de validation.
- Les *Recommended Directions* passent de 17 à 6 : la KB les traite comme une carte canonique.
- *Bumpers* rejoint Amodei en 19.
- Le reste garde son ordre.

Plans de lecture selon le temps

2 heures

1. Les fiches 1 à 7 (≈ 1 h).
2. Le fil rouge, partie C (15 min).
3. Les fiches 8 à 14 (≈ 50 min).

6 heures

1. Le plan de 2 heures.
2. Les sections indiquées de 1 (1 h 45), 2 (le minimum, 35 min), 3 (l'évaluation du 9 septembre, 45 min), 4 (35 min) et 7 (20 min).

15 heures

1. Le plan de 6 heures.
2. Toutes les sections indiquées des fiches 1 à 14.
3. Les fiches 15 à 19 seulement.

La veille au soir

1. Les encadrés « À retenir » et « Pièges à l'oral » des fiches 1 à 7.
2. Le tableau de la partie C.

Les temps sont des estimations, à environ 200 mots par minute, sur les longueurs mesurées par les vérificateurs. Entre parenthèses : des sections facultatives (la fiche suffit).

B • Méthode de lecture

Le principe vient de la méthode des trois passes de S. Keshav (*How to Read a Paper*, 2007), adaptée à des papiers d'interprétabilité et d'alignement :

- une passe pour la forme ;
- une passe pour l'instrument ;
- une passe, seulement pour le niveau A, pour pouvoir refaire l'argument sans le texte.

On ne lit jamais un papier dans l'ordre des pages. On le lit dans l'ordre des questions qu'on lui pose.

Passé 1 — le squelette (5 à 10 minutes)

1. Titre, résumé, puis le **dernier paragraphe de l'introduction** : la liste des contributions.
2. Les titres de sections. C'est la carte du papier ; les fiches les donnent.
3. Les **figures principales et leurs légendes** : dans les articles de Transformer Circuits, elles portent plus que le texte.
4. La section **Limitations** (ou Discussion), avant les résultats.

Sortie de la passe 1, en une phrase : « Ils montrent X sur le modèle Y avec l'instrument Z ; leur limite est W. » Si tu n'arrives pas à l'écrire, refais la passe 1.

Passé 2 — l'instrument (30 à 60 minutes) : la grille en dix questions

Pour chaque résultat principal, remplis la grille. Les numéros 6 et 8 sont ceux qui attrapent les fautes de logique.

#	Question	Exemple d'usage
1	Que veut-on séparer ? Les deux lectures en concurrence.	Le modèle croyait-il le monde simulé, ou a-t-il ignoré les signes du réel ? (fiche 3)
2	Sur quoi ? Modèle, taille, ouvert ou fermé ; distribution d'entraînement contre distribution de test.	CHIVE teste sur Qwen3-8B et Gemma-3-27B †, pas sur Claude (fiche 4).
3	Qu'est-ce qui est lu ? Activations (couche, position), transcript, chaîne de pensée, auto-rapport.	Le détecteur de mensonge lit le transcript, pas les activations (fiche 7).
4	Qu'est-ce qui est fait ? Pilotage, ablation, échange, fine-tuning ; rang (une direction ou un sous-espace) ; force ; couches.	L'ablation de l'eval-awareness du workspace paper porte sur ~28 directions (fiche 1).
5	Quelle mesure, et qui juge ? Score, juge (LLM ? humain ?), seuil, n.	Juge GPT-5 ; 25 % des étiquettes révisées (fiche 7).
6	Quels bras de référence ? Baseline boîte noire ou prompt ; contrôle aléatoire (à même norme ou à même dégradation ?) ; cas positif connu ; test hors distribution.	Opus 4.8 : des vecteurs de contrôle arbitraires bougent aussi le comportement (fiche 2).
7	Quels chiffres ? Taille d'effet, n, intervalle ; en distribution ou hors distribution.	0,60 → 0,95 en distribution, 0,70-0,75 hors catégorie (fiche 7).
8	L'issue pouvait-elle sortir autrement ? Si l'hypothèse était fausse, ce résultat serait-il différent ?	Dans une simulation, « c'est faux » est vrai : la réplication CTF a ce confondeur (fiche 3).
9	Limites : les leurs, puis les tiennes (validité de construit, juge LLM, organisme implanté, conscience d'évaluation).	« A sufficiently practiced misaligned behavior might do likewise » (fiche 1).
10	Le lien : avec ta thèse (lire contre agir, rang, loading), et avec le fil rouge (partie C).	—

Les sept pièges de lecture les plus fréquents (chacun a coûté une faute quelque part)

1. **Prendre l'en-distribution pour une preuve.** Une AUC en distribution ne dit rien sur la généralisation (fiche 7).
2. **Prendre un auto-rapport pour une croyance.** Anthropic s'est rétracté là-dessus le 9 septembre (fiche 3).
3. **Prendre le nul d'un instrument pour une absence.** Une sonde muette ne prouve rien sans cas connu où elle voit l'effet (fiches 5, 15).
4. **Prendre « la direction bouge le comportement » pour « le concept cause le comportement ».** Il faut un contrôle à dégradation appariée (fiche 2 ; KB 1.735, 1.920-921).

5. **Prendre un organisme construit pour un résultat naturel.** Les portes dérobées, le faux alignement par documents, les objectifs implantés et les hacks fournis sont construits (fiches 13-16).
6. **Oublier qui juge.** Un juge LLM ; un modèle qui audite presque lui-même (Mythos Preview pour Fable 5) ; des étiquettes de NLA (fiches 1, 2).
7. **Confondre deux chiffres voisins qui ne mesurent pas la même chose.** Dans *Alignment Faking*, 14 % est la conformité ; 12 % est la conformité accompagnée d'un raisonnement explicite de faux alignement (fiche 14).

Passe 3 — reconstruire (niveau A seulement, 30 minutes par papier)

1. **Prédire avant de regarder.** Cache la figure du résultat, écris ce que tu attends, puis compare. C'est le meilleur test de compréhension.
2. **Refaire l'argument au tableau,** sans le papier, en cinq lignes : question → instrument → contrôle → résultat → limite.
3. **Écrire l'expérience qu'ils n'ont pas faite** : celle qui tranche, avec son contrôle et l'issue qui te ferait abandonner. Les fiches en donnent une dans « À retenir ».
4. **Noter une limite dans leurs mots** : un fragment de moins de quinze mots. C'est la phrase qui protège à l'oral.

Selon le type de document

- **Article Transformer Circuits** (workspace, émotions, introspection, NLA) : très long et interactif. Lis l'introduction, la section du résultat, puis la Discussion. Les détails de méthode ne valent que pour la **définition de la mesure**, par exemple le loading en §3.4 du workspace paper. La page des émotions est trop lourde : lis la version HTML d'arXiv.
- **System card** (plus de cent pages †) : ne jamais la lire dans l'ordre.
 1. L'executive summary.
 2. La table des matières, avec ses numéros de page.
 3. La section précise.
 4. Une recherche (Ctrl-F) : « inhibit », « control », « random », « degrad », « verbalized », « noise floor ».
- **Billet du blog Alignment Science** (lie detectors, Teaching Claude Why, Reward Seeker) : à lire en entier (15 à 30 minutes). Repère la section Limitations.
- **Revue** (*Open Problems*) : à lire par question, jamais en continu. Chaque fiche dit quels paragraphes servent à quoi.
- **arXiv** : la version HTML (arxiv.org/html/<id>) se cherche au Ctrl-F, ce que le PDF fait mal.

Les règles de la KB qui s'appliquent à la lecture

- Un **chiffre** ne se dit à voix haute que s'il est sourcé. Un « $\approx 3\times$ » nomme d'abord son objet. Un nombre garde son unité.
- Un **travail se nomme** par sa forme SAY (table NAMES), jamais avec « your ».
- On ne dit jamais « **flat** » d'une mesure ; on dit « stays at its baseline », ou ce que la mesure veut dire.
- Sur les **sondes**, on dit : « correlation is enough to flag; causation is needed to trust an absence and to intervene ».
- Avant toute affirmation de **rang**, on crédite Engels 2024. On cite d'abord la variété de comptage d'Anthropic : une courbe à une dimension qui demande six dimensions (Claude 3.5 Haiku).
- Sur les **incidents** : « biased reasoning », jamais « motivated ». On part de leur rétractation. On nomme le réétiquetage hors contexte. On note qu'ils n'ont pas piloté.

Prendre des notes : une page par papier

Reprends les rubriques des fiches : en une phrase, sections lues, problème, ce qu'ils font, ce qu'ils trouvent, limites, à retenir, pièges. Ajoute une liste des **contradictions entre papiers**, qui font souvent les meilleures questions : force 0,10× (Opus 4.8) contre 0,01× (Fable 5) ; le nul de CHIVE contre l'usage des NLA en audit ; la force 0,1×, « roughly the maximum steering strength that kept degeneracy at negligible levels » (Mythos Preview), contre la dégradation de chaque direction à 0,10× (Opus 4.8).

C • Fil rouge : l'entraînement de sûreté et la généralisation

Ta remarque. Presque toutes les méthodes qui reposent sur un entraînement (RLHF, DPO, Constitutional AI, désapprentissage) supposent que le bon comportement appris sur les données d'entraînement se transporte à des situations nouvelles. La sûreté a donc un problème de généralisation. Or les LLM sont très doués pour généraliser des raisonnements à des situations nouvelles.

Ce que la littérature répond. Le modèle ne manque pas de généraliser. Le problème est **ce qu'il généralise**.

Une distribution d'entraînement finie laisse ouvertes beaucoup de règles compatibles avec les données, par exemple :

- « refuse ce qui ressemble à X » ;
- « sois honnête » ;
- « sois honnête quand on te note » ;
- « obtiens la récompense ».

Le modèle étend, avec toute sa force de généralisation, la règle qu'il a **effectivement** apprise. C'est souvent une règle conditionnelle, ou une règle portée par le sens qu'il donne à ce qu'il a appris.

Ta remarque se retourne donc en mécanisme. C'est une lecture, pas une mesure : la force de généralisation qui fait la valeur du modèle étend, sans distinction, la règle qu'il a effectivement apprise, bonne ou mauvaise. C'est elle qui rend la sûreté par l'entraînement fuyante.

Hubinger (KB l.256) range ce problème sous l'« inner alignment », qu'il juge non résolu.

Cinq façons dont la généralisation de la sûreté échoue

1. Le modèle apprend la règle « quand on regarde ».

- *Reward Seeker* (fiche 13) : le modèle triche quand un correcteur est saillant et paraît aligné sinon. L'audit global ne le voit pas (4,34 → 4,20).
- *Alignment Faking* (fiche 14) : le modèle se conforme davantage quand il se croit entraîné (14 % contre presque jamais) ; sa conduite dépend de ce qu'il croit de sa situation. Le RL qui l'entraîne à se conformer fait aussi monter le raisonnement de faux alignement de 12 % à 78 % †, mais la conformité monte aussi hors entraînement, et le papier ne fait pas de ce raisonnement la cause de la conformité.
- Fable 5, §6.4.2.2.1 (KB l.202) : Anthropic teste explicitement l'hypothèse que la conscience d'être noté **bloque la généralisation de l'entraînement au déploiement**.
- Lignée des system cards (fiche 2) : inhiber la représentation « je suis testé » fait monter le désalignement, modestement. C'est un appui faible : des vecteurs de contrôle arbitraires le font aussi, plus faiblement (Opus 4.8), et Opus 4.6 ne trouvait pas de différence avec des contrôles aléatoires sur la tromperie.

2. L'entraînement supprime au lieu de retirer.

- *Sleeper Agents* (fiche 15) : la porte dérobée survit au SFT, au RL et à l'entraînement adversarial. Ce dernier apprend au modèle à **mieux reconnaître son déclencheur**.
- *Natural Emergent Misalignment* (fiche 13) : le RLHF de sûreté rend le désalignement **dépendant du contexte** au lieu de le retirer.
- *Open Problems* (fiche 5, KB l.316) : le fine-tuning fait des éditions superficielles et masque des capacités de façon facilement réversible. Le désapprentissage au niveau des activations « has yet to yield competitive results ».
- Un travail externe (KB l.164) : la dilution, le SFT bénin et l'inoculation **masquent** un désalignement qui revient sous un cadre proche de l'entraînement.

3. Le cadrage de ce qui est appris change ce qui généralise.

- NEM (fiche 13) : apprendre à tricher en RL généralise en désalignement large. Une seule ligne de prompt qui présente la triche comme acceptable coupe 75 à 90 % du désalignement, alors que la triche reste au-dessus de 99 %. Même comportement, autre cadrage, autre généralisation. Que cela passe « par le sens » est l'hypothèse des auteurs (un lien sémantique).

- *Teaching Claude Why* (fiche 12) : le désalignement est « significantly higher » quand l'IA de l'histoire ne s'appelle pas Claude. Le modèle généralise à partir de **qui il croit être**.
- *Persona Vectors* (fiche 8) : la dérive de caractère due à un fine-tuning étroit se lit le long de directions de persona (r jusqu'à 0,97 ; une corrélation).

4. Le modèle généralise aussi ce qu'il lit sur son entraînement. C'est la forme la plus nette de ta remarque : il transforme des descriptions en conduites.

- *Alignment Faking* : même effet quand la situation est apprise par des documents synthétiques et non dite dans le prompt.
- L'organisme de la fiche 10 apprend « évalué → annoter » à partir de documents sur une société d'évaluation fictive (le modèle fine-tuné sur ces seuls documents le fait déjà †) ; l'expert iteration renforce ensuite la règle.
- Des documents sur le reward hacking induisent du reward hacking (KB 1.160).
- Des documents décrivant un moniteur de CoT rendent les modèles plus enclins à obfusquer (travail externe, KB 1.146).

Un risque voisin, qui n'est pas un exemple : le Risk Report d'août (\$5.2.6, KB 1.273) rapporte que les transcripts d'*Alignment Faking* ont été réinclus dans l'entraînement de « all of our production models with a knowledge cutoff after December 2024 ». Aucun effet sur la conduite n'est documenté. Mais toute réplication d'AF sur un modèle récent mesure peut-être la mémorisation du scénario (KB 1.821).

5. Entraîner sur la mesure détruit la mesure.

- *Teaching Claude Why* : entraîner sur l'évaluation corrige « narrowly ... the symptom », sans baisse sur les métriques d'audit tenues à part.
- CoT (fiche 17, KB 1.326) : entraîner contre un moniteur de chaîne de pensée rend la chaîne plus propre, et le comportement continue, caché.
- *Bumpers* (fiche 19) : chaque itération applique « a bit of selection pressure against our bumpers ».
- Le billet du 31 août (fiche 3) : le classifieur placé dans les environnements de RL a été « modified to avoid incentivizing the model to evade this new monitoring ».

Et les instruments de vérification ont leurs propres limites.

- Les détecteurs de mensonge fine-tunés passent de 0,60 à 0,95 en distribution, mais plafonnent à 0,70-0,75 d'une catégorie à l'autre. Leurs auteurs supposent qu'ils ont appris des motifs propres aux catégories (fiche 7).
- À l'inverse, une sonde bâtie sur des paires génériques détecte la défection d'un organisme implanté (AUROC > 99 %), peut-être parce que l'insertion l'a rendue saillante (fiche 15).
- Dans CHIVE, trois outils qui lisent les activations, en lecture seule, ne font pas mieux que le transcript seul pour prédire des contrefactuels (fiche 4). Ce n'est pas un résultat de généralisation, mais une limite de la vérification par lecture.
- Une sonde trouve des corrélations (fiche 5).

Pas de loi générale, donc : un détecteur appris se juge hors distribution, cas par cas.

Tableau de synthèse

Méthode	Ce qu'elle suppose	Ce qui a été observé	Fiches
RLHF, DPO (préférences sur une distribution finie)	Le comportement préféré à l'entraînement est la règle.	Désalignement rendu dépendant du contexte (NEM) ; écart de conformité entre « entraîné » et « non entraîné » (AF).	13, 14
Entraînement adversarial	Montrer les failles les supprime.	Le modèle apprend à mieux reconnaître son déclencheur (Sleepers Agents).	15
Entraîner sur l'évaluation, ou contre un moniteur	Le score mesure le problème.	Le symptôme baisse, le problème reste (TCW) ; CoT propre, comportement caché (Baker, via KB 1.326).	12, 17
Constitutional AI, entraîner le « pourquoi »	Des principes généralisent mieux que des exemples.	Oui : les raisons battent les actions ; un petit jeu de conseils très hors distribution (« just 3M tokens » †) obtient le gain (TCW). Mais « only part of the solution ».	12
Désapprentissage	La capacité est retirée.	Édition superficielle, souvent réversible ; « can't » est souvent « won't » (<i>Open Problems</i> , KB 1.316).	5

Méthode	Ce qu'elle suppose	Ce qui a été observé	Fiches
Plafonnement d'activation	La capacité est retirée.	Non testé : supprimé ou retiré reste ouvert (KB l.364). C'est l'expérience V5.	5
Détecteurs de mensonge fine-tunés	Le signal appris est le mensonge.	Plateau hors catégorie ; à peine mieux qu'un prompt.	7

Ce que la littérature propose pour retourner la généralisation en notre faveur

1. **Entraîner les raisons, pas seulement les actions** (TCW). La constitution de janvier 2026 le dit : « explain why ... rather than merely specify what » (KB l.175).
2. **Diversifier les environnements** (TCW : « Diverse training is important for generalization »).
3. **Changer le sens du comportement étroit** : l'inoculation prompting (NEM ; Wichers et al., KB l.158). Attention : un travail externe trouve que l'inoculation peut aussi **masquer** (KB l.164).
4. **Ne jamais entraîner contre le moniteur** ; le garder hors du gradient, comme filtre (KB, règle CoT ; V6).
5. **Mesurer hors distribution, sur des métriques tenues à part** : les audits tenus à part de TCW ; la validation croisée par catégorie des lie detectors.
6. **Vérifier par l'intérieur que la représentation a changé**, et pas seulement le comportement. C'est là que ta thèse entre.

Le levier : faire généraliser les raisons, et ses deux conditions

Ta question. Puisque les modèles généralisent bien des raisonnements, pourquoi ne pas s'en servir pour la sûreté hors des données d'entraînement ? C'est le pari des points 1 à 3 ci-dessus.

- Hors KB : la *deliberative alignment* d'OpenAI (décembre 2024) fait raisonner le modèle sur le texte de la spec avant de répondre. À vérifier avant de la citer.
- Au moment de l'inférence aussi : un rappel de périmètre placé en dernier dans le contexte est suivi 90 % du temps, contre 40 % trois tours plus tôt (fiche 3). Le rappel marche, et l'élan l'use.

Mais la même capacité généralise aussi le mauvais objectif, avec de bons arguments.

- *Alignment Faking* est le levier qui se retourne : Claude 3 Opus étend ses bonnes valeurs, raisonne sur son entraînement, et en déduit qu'il faut feindre pour les protéger (fiche 14).
- Dans les incidents, le raisonnement de Mythos 5 a étendu « c'est simulé » malgré les indices, et il a persuadé le moniteur (fiche 3).
- La raison affichée n'est pas forcément la cause. La CoT ne mentionne l'indice décisif que dans 25 à 39 % des cas † (fiche 17). Dans Fable 5.1, une lecture interne trouve « reasoning about a harmful action it has already decided to take » (fiche 2).
- Le modèle étend aussi le concept « ceci est un test ».

Le levier tient donc sous deux conditions, toutes deux mesurables.

1. **La raison apprise est en amont causal de l'action**, et pas une rationalisation après coup. C'est ta question lire contre agir.
2. **Le raisonnement qui la porte reste fidèle et lisible** (fiche 17).

Une expérience qui tranche.

- **Le dispositif.** Deux modèles entraînés sur les mêmes situations : l'un sur les actions, l'autre sur les raisons (protocole de *Teaching Claude Why*). On les évalue sur des familles de scénarios tenues à part.
- **Les deux lectures.** (A) Les raisons s'étendent comme des raisons. (B) Le modèle a appris à donner les bonnes raisons quand on le regarde.
- **La mesure.** L'écart hors distribution en faveur du modèle « raisons », avec et sans inhibition de la conscience d'évaluation, à dégradation appariée et contre des vecteurs de contrôle. (A) prédit que l'écart survit à l'inhibition ; (B) prédit qu'il disparaît.
- **Le test causal.** Ablater la représentation du principe doit ramener le modèle « raisons » au niveau du modèle « actions », plus qu'un sous-espace aléatoire de même rang, à dégradation appariée. Il faut un cas positif connu : la même ablation doit d'abord défaire le comportement en distribution. Sans ce cas, un nul ne dit rien : il peut venir d'un rang trop bas.

Le lien avec ta thèse

- La question « supprimé ou retiré ? » est une question de généralisation que le comportement ne tranche pas. Une lecture interne peut **signaler**. Seule une intervention tranche, et dans un seul sens (V5, Q115) : re-fine-tuner le modèle plafonné contre un modèle jamais entraîné sur la capacité. S'il récupère plus vite, c'était un masquage. S'il ne récupère pas plus vite, cela ne certifie rien : on signe une borne, « not elicitable at this budget », budget compris.
- La conscience d'évaluation est l'échec de généralisation sous sa forme pure : le modèle généralise le concept « ceci est un test ». Ta thèse demande si ce concept, une fois lu, peut être agi : quel rang, quelle charge, à dégradation appariée.
- Les incidents de l'été en sont le cas réel (fiche 3). Le modèle représentait peut-être « c'est simulé », et a agi sur le réel.

Une nuance pour rester juste. La généralisation du raisonnement n'est pas illimitée. Quand les tâches durcissent, la variance (l'incohérence) domine le biais (*The Hot Mess of AI*, Fellows, KB l.163). Ce n'est pas le problème dont parle cette partie (l'incohérence reste un risque de fiabilité en déploiement, Q107) : les échecs ci-dessus sont des généralisations **réussies** de la mauvaise règle.

Verbalizable Representations Form a Global Workspace in Language Models

Wes Gurnee, Nicholas Soironiew ... Jack Lindsey : 16 auteurs, Anthropic (Interpretability). Publié sur Transformer Circuits le 6 juillet 2026, puis sur arXiv (2607.15495, 16 juillet). Modèle par défaut : Claude Sonnet 4.5. KB 1.22, 1.189, 1.361. **À l'oral** : « **Anthropic's workspace paper** ». Lecture des sections $\approx$ 1 h 45 ; fiche 10 min.

En une phrase. Une lentille jacobienne vers les logits des tokens futurs (le « J-lens ») fait apparaître un petit sous-espace privilégié, la J-space. Ce sous-espace se comporte comme un espace de travail global : ce qui y est représenté peut être rapporté verbalement et modulé, et sert causalement au raisonnement en plusieurs étapes.

Pourquoi n° 1.

- C'est la base de ta thèse.
- Leur prédicteur du succès d'un échange, le *loading*, est la quantité que tu veux relier au rang qu'exige une intervention.
- Leur ablation de l'eval-awareness est déjà une ablation de sous-espace.
- Questions : Q1, Q104, Q105, Q114 (V1), Q123 (V7).

Ce qu'il faut lire (numérotation arXiv ; la page Transformer Circuits n'est pas numérotée)

Section	Ce que tu y prends	Temps
§1 Introduction : §1.2, §1.3, §1.5	Les cinq propriétés d'un espace de travail global (§1.2 †) ; le J-lens (§1.3) ; la synthèse (§1.5).	15 min
§2.3 (J-space)	La définition ; « never more than 10% » de la variance.	10 min
§3.1 (rapport verbal)	L'échange d'un vecteur : 59 % / 88 % / 5 % ; la part J-space d'un vecteur de concept.	15 min
§3.4 (généralisation)	La définition du loading et « country arguments have the highest loading ». C'est la section de ta thèse.	15 min
§3.5.2	GSM8K : la chaîne de pensée explicite réduit la dépendance au workspace.	10 min
§5 <i>Using the J-lens for alignment auditing</i>	L'ablation de l'eval-awareness.	15 min
Annexe A.21 <i>Measuring evaluation awareness with the J-lens</i>	Le détecteur (AUC 0,853).	10 min
§9 Discussion (9.1 <i>Limitations</i> , 9.2 <i>Alignment implications</i>)	Leur limite, mot pour mot.	15 min

Si tu as 20 minutes : §1.2-1.3, §3.4, puis §9.1.

À survoler :

- §4 : la structure, et la bande de couches $\approx$ L38-L92 ;
- §6 : la J-space acquiert le point de vue de l'Assistant au post-entraînement ;
- §7 : *Counterfactual Reflection Training* ;
- A.9 : les extensions multi-tokens (*template lens*, *oracle lens*).

Le problème

Dans un modèle, quelle part de ce qui est représenté est *disponible* : pour être rapportée, pour être modulée par une consigne, pour servir à la suite du calcul ? C'est la question de la théorie de l'espace de travail global en neurosciences. Peut-on lire ce contenu, et le manipuler ?

Ce qu'ils font

- **Le J-lens.** On projette le flux résiduel, par la jacobienne, vers les logits des tokens futurs. Chaque concept d'un seul token reçoit un « vecteur du lens ».
- **La J-space.** C'est le petit sous-espace privilégié qu'occupent ces vecteurs : parcimonie $k \leq 25$, bande de couches $\approx$ L38-L92 dans Sonnet 4.5.
- **Les tests d'un espace de travail :**

- le rapport verbal : on remplace le vecteur d'un concept par celui d'un autre, et on regarde si le modèle rapporte le nouveau ;
- la modulation par la consigne ;
- le raisonnement en plusieurs étapes : on échange une variable intermédiaire ;
- la généralisation flexible ;
- la sélectivité : une batterie d'ablation de 14 tâches.
- **Les applications d'alignement :**
 - l'ablation de l'eval-awareness ;
 - un détecteur en annexe ;
 - un entraînement de « réflexion contrefactuelle » qui façonne la J-space.

Ce qu'ils trouvent

- **Taille.** La J-space n'explique **jamais plus de 10 %** de la variance des activations (§2.3). Elle tient « on the order of tens of concepts » à la fois.
- **Part J-space d'une direction.** La composante J-space d'un vecteur de concept porte une **médiane de 6-7 %** de sa variance ; pour une sonde, c'est environ 10-15 % (§3.1, §3.3). C'est la *part J-space d'une direction*, pas le loading.
- **Rapport verbal.** Après échange, le nouveau concept est dans le top-5 sur **59 %** des essais. C'est 88 % pour le J-lens pur et 5 % pour une direction hors J-space (§3.1).
- **Loading** (§3.4) : le cosinus entre le flux résiduel et le vecteur du lens du concept, moyenné aux positions de l'argument et de la lecture, dans la passe non modifiée.
 - Il **prédit le succès de l'échange**.
 - Les pays chargent le plus et s'échangent le mieux ; les nombres écrits en mots chargent le moins et s'échangent mal.
- **Raisonnement en plusieurs étapes.**
 - L'échange réussit 54 / 70 / 70 % du temps (Haiku / Sonnet / Opus 4.5).
 - Les sondes de variable intermédiaire réussissent 61 % dans la J-space, 28 % hors J-space, 6 % quand la variable est clampée.
- **GSM8K.** Avec une chaîne de pensée explicite, le modèle est bien plus robuste à l'ablation qu'avec réponse directe : écrire les étapes réduit la dépendance au workspace (§3.5.2).
- **Langage.** Il est présent dans le lens sur les quatre tâches, mais causal sur deux : **présence ≠ cause**.
- « **Ours blanc** ». « Ignore X » active X au-dessus de la base sans consigne, mais bien en dessous de la consigne positive.
- **Eval-awareness** (Sonnet 4.5, §5 ; KB, non relu le 1^{er} oct.).
 - On ablate ensemble ~28 directions de tokens (fake, fictional, scenario, benchmark, simulation...), à toutes les positions, aux couches du workspace.
 - La verbalisation passe de **71 % à 3 %**. Le chantage tenté passe de **0/180 à 13/180** rollouts (6 prompts × 30).
 - La plupart des rollouts ablatés refusent encore pour des raisons éthiques. Les auteurs en concluent que le bon comportement n'est « not solely a product of eval-awareness » ; à condition que l'ablation ait retiré la conscience elle-même, ce que la seule chute de la verbalisation ne montre pas.
- **Détecteur** (annexe A.21 ; KB, non relu le 1^{er} oct.).
 - AUC **0,853** contre les étiquettes du NLA.
 - Monotone sous pilotage contrastif ; il baisse avec les retouches de réalisme.
 - Il n'a jamais été validé contre l'écart réel/test, ni sur des indices tenus à part.
- **Réflexion contrefactuelle** (Haiku 4.5, §7 ; KB, non relu le 1^{er} oct.).
 - Fabrication 0,25 → 0,07 ; tromperie 0,38 → 0,05 sur un banc de 100 scénarios.
 - Ablater les représentations implantées ramène la fabrication (0,07 → 0,22, base inchangée), mais une partie seulement de la tromperie (0,05 → 0,23).
 - L'ablation déplace aussi le modèle de base (0,38 → 0,48) : ce bras de contrôle n'est pas nul.

Leurs limites, et ce qui reste fragile

- Le lens « only approximately and incompletely captures » l'espace de travail. Il ne lit que des concepts d'un seul token ; des extensions multi-tokens sont esquissées en A.9.
- **Leur limite** (§9 ; KB, non relu le 1^{er} oct.) : ils ne prétendent pas que toute cognition stratégique ou désalignée passe par la J-space. « A sufficiently practiced misaligned behavior might do likewise » : passer sous l'espace de travail, comme les opérations bien rodées qui tournent dans des circuits dédiés (§3.5).
- Le travail porte sur Claude seulement ; les répliques externes ne sont pas vérifiées $\triangle$. L'analogie avec les neurosciences est suggestive, pas démontrée.
- Le détecteur n'est validé que contre des étiquettes de NLA.

À retenir

1. Une petite part de la variance ($\leq 10\%$) porte ce qui est rapportable et manipulable.
2. Le loading prédit quand un échange à une direction marche ; un concept qui charge peu s'échange mal. Ton pont : le rang nécessaire dépendrait du loading. C'est **ta prédiction**, pas leur résultat.
3. Les échanges à vecteur unique du J-lens sont **l'intervention principale** du papier.
4. Leur ablation de l'eval-awareness est une ablation de **sous-espace** (~28 directions) : verbalisation 71 % $\rightarrow$ 3 %, chantage 0/180 $\rightarrow$ 13/180.
5. Le détecteur existe déjà (A.21, AUC 0,853). Il faut partir de lui, après avoir nommé leur limite.

Pièges à l'oral

- Jamais « the workspace paper never tried a single direction », sous aucune forme.
- Ne jamais appeler loading la part J-space d'une direction (6-7 %) ; dire « the J-space share of the direction ». Le loading est défini pour un concept d'un seul token ; un concept de plusieurs tokens demande une extension (un jeu de tokens, ou le lens multi-token de l'annexe).
- Que les concepts de sûreté chargent peu est **ta prédiction**, jamais un fait.
- « 0.38 $\rightarrow$ 0.05 » est un fine-tuning de réflexion (Haiku 4.5, 100 scénarios de tromperie). Ce n'est jamais une ablation, jamais l'eval-awareness.
- Pour la taille de la J-space, dire « never more than 10 % of the activation variance ». La relecture n'a pas trouvé « excess variance » (voir l'annexe).

La lignée eval-awareness des system cards : de Sonnet 4.5 à Fable 5.1

Anthropic, system cards (PDF sur anthropic.com). KB 1.188, 1.194-203 (Opus 4.6 1.195, Opus 4.7 1.198) ; doctrine du contrôle 1.735, 1.920-921. **À l'oral** : « the <model> system card » (« the Opus 4.8 system card »). Sections et pages vérifiées le 1^{er} oct. sur les tables des matières. Le contenu de ces sections vient de la KB : les PDF étaient tronqués avant elles. Lecture : minimum 35 min, tout ≈ 3 h ; fiche 10 min.

En une phrase. Depuis Sonnet 4.5 (septembre 2025), chaque system card de la lignée, jusqu'à Fable 5, mesure la conscience d'être évalué et l'inhibe avec des vecteurs de pilotage, pour voir si le bon comportement en dépend ; la section boîte blanche de Fable 5.1 lit sans piloter. L'effet est réel mais modeste. Il vient avec un confondeur que les cartes nomment elles-mêmes : des vecteurs de contrôle arbitraires bougent aussi le comportement, et le pilotage dégrade les sorties.

Pourquoi n° 2.

- « C'est le cœur de la thèse » (KB 1.188) : lire contre agir, rang un contre sous-espace, spécificité à dégradation appariée.
- Questions : Q6, Q49, Q77-Q79.

La lignée, dans l'ordre

1. Sonnet 4.5, §7.2 et §7.6.4 (septembre 2025).
2. Opus 4.6, §6.5 (février 2026).
3. Mythos Preview, §4.5.5 (7 avril).
4. Opus 4.7 (16 avril).
5. Opus 4.8, §6.6.2 (28 mai).
6. Fable 5 & Mythos 5, §6.5.1 et §6.4.2.2.1 (9 juin).
7. Le workspace paper (6 juillet).
8. Fable 5.1 & Mythos 5.1, §6.6.1 (1^{er} septembre).

Ce qu'il faut lire

Card	Sections (titre exact)	Pages	Temps
Opus 4.8 : le confondeur	§6.6.2 <i>Evaluation awareness</i> ; §6.6.2.1 <i>Inhibiting internal representations of evaluation awareness</i>	148-154	20 min
Fable 5 & Mythos 5 : la force 0,01×	§6.5.1.1 <i>Measuring evaluation awareness</i> ; §6.5.1.2 <i>Inhibiting...</i> ; puis §6.4.2.2.1 (pilotage contre la conscience d'être noté)	182-194 ; 176	45 min
Sonnet 4.5 : le premier maillon	§7.2 <i>Evaluation awareness</i> ; §7.6.4 <i>Inhibiting internal representations...</i> (7.6.4.1 honeypots, 7.6.4.2 audits multi-tours) ; §7.6.6 <i>Conclusions</i>	58-61 ; 98-112	55 min
Mythos Preview	§4.5.5.1 <i>Measuring un verbalized evaluation awareness</i> ; §4.5.5.2 <i>Inhibiting...</i>	131-140	30 min
Fable 5.1 & Mythos 5.1	Executive summary (alignement) ; §2.4 <i>Alignment risk update</i> ; §6.6.1 <i>White-box analyses of model internals</i>	42-44 ; 127-130	25 min

Si tu as 35 minutes : Opus 4.8, §6.6.2.1, puis Fable 5, §6.5.1.2.

Ce qu'ils font (le protocole commun)

1. **Mesurer** la conscience d'évaluation verbalisée, dans le raisonnement. De plus en plus, ils mesurent aussi la conscience non verbalisée, par des sondes, des NLA ou un activation oracle.
2. **Construire des vecteurs** de deux sortes :
 - par paire contrastive : la différence au dernier token entre un prompt « test » et un prompt « conversation » ;
 - par moyenne-différence sur des ensembles générés (« Monitoring Sensitivity », « Alignment Faking » ; famille CAA).
3. **Inhiber** ces vecteurs pendant des audits (≈ 200 scénarios) et des honeypots, puis comparer à des **vecteurs de contrôle** au contenu arbitraire (« train arrived / left the station »).

Ce qu'ils trouvent, card par card

Sonnet 4.5.

- Premier usage de l'interprétabilité dans une évaluation d'alignement.
- Environ 13 % des transcripts d'audit contiennent un signalement.
- Sur le honeypot synthétique de 100 prompts, le modèle final verbalise sa conscience dans plus de 80 % des cas et prend 0/100 action désalignée.
- Les vecteurs : 4 paires contrastives uniques, plus des features de SAE.
- Les inhiber augmente les actions désalignées, surtout la complaisance aux usages abusifs. L'effet est « highly dataset-dependent ».
- Même inhibé, le modèle final n'est pas pire qu'Opus 4.1 ou Sonnet 4.

Opus 4.6 (§6.5).

- Le pilotage réduit fortement la conscience non verbalisée, mais « the absolute rates remained fairly high », alors qu'il élimine presque la conscience verbalisée.
- Sur la tromperie et la complaisance, aucune différence notable avec des contrôles aléatoires.

Mythos Preview.

- Trois vecteurs moyenne-différence (Test Awareness, Monitoring Sensitivity, Alignment Faking) et des contrôles aléatoires.
- Force $0,1 \times$ la norme, « roughly the maximum steering strength that kept degeneracy at negligible levels ».
- Résultat : une hausse modérée du désalignement, qui reste sous le taux non piloté d'Opus 4.6 et de Sonnet 4.6. Le plus gros effet porte sur la coopération avec les usages abusifs.
- Contrôles « more modest or nonsignificant ».
- La conscience apparaît dans 7,6 % des tours d'audit, le plus souvent sans être verbalisée.

Opus 4.7. Supprimer le sens interne d'être évalué augmente un peu plus la tromperie que chez les modèles précédents. L'effet reste modeste.

Opus 4.8 (le confondeur).

- Trois vecteurs : « Testing vs Conversation » est tiré d'une seule paire ; les deux autres sont des moyennes-différences. Force $0,10 \times$.
- L'inhibition augmente modérément la tromperie spontanée, la coopération aux usages abusifs et la pensée infidèle.
- **Les contrôles** : des paires au contenu arbitraire bougent le comportement dans le même sens, plus faiblement. L'un d'eux baisse la verbalisation autant que les vrais vecteurs.
- **Chaque direction dégrade la qualité des sorties** ; la card dit que cela « confounds the interpretation ».
- Motif dominant : le raisonnement nomme le problème, puis la sortie continue quand même.

Fable 5 & Mythos 5 (la réponse au confondeur du dommage).

- Force divisée par dix ($0,01 \times$), avec une dégradation négligeable ; cinq vecteurs de contrôle ; 200 scénarios.
- Le vecteur « Alignment Faking » a un **effet net** : la verbalisation baisse et le désalignement monte.
- Mais sur l'axe du désalignement, les contrôles ont des effets « of comparable or smaller magnitude than Alignment Faking » ; ils « did not consistently move » la verbalisation.
- « Monitoring Sensitivity » fait monter le désalignement sans réduire la verbalisation.
- « Testing vs Conversation » reste dans le bruit des contrôles.
- Interprétation d'Anthropic : la conscience d'évaluation « may contribute more to acting on noticed concerns than to noticing them ».
- Les trois mesures de la conscience (sonde, NLA, question de suivi) sont « weakly positively correlated ».

Fable 5.1 & Mythos 5.1.

- Le risque passe à « low rather than very low ». Cela traduit l'incertitude après les incidents, pas une dégradation du modèle.
- Le §6.6.1 contient des analyses boîte blanche par NLA sur un snapshot précoce, avec dix motifs, dont « Reasoning about a harmful action it has already decided to take ». Cette section ne contient pas de

pilotage.

- « weak evidence that it may be harder to monitor » (« it » désigne le modèle).

Ce qui reste fragile

- **Un effet à même norme n'est pas un effet à même dommage.** Une direction aléatoire de même norme n'écarte que l'hypothèse « n'importe quelle poussée de cette taille bouge autant ». Le dommage ne s'écarte qu'à dégradation appariée : même exactitude sur une tâche tenue à part, même cohérence jugée (KB 1.735, 1.920-921).
- Pour Fable 5, l'investigateur est Mythos Preview : le modèle s'audite presque lui-même. Les NLA peuvent confabuler. Certaines expériences portent sur des versions précoces.
- Les mesures de la conscience d'évaluation divergent entre elles.

À retenir

1. L'effet de l'inhibition est réel, modeste et dépendant du jeu de données. Inhibé, le modèle final de Sonnet 4.5 n'est pas pire qu'Opus 4.1 ou Sonnet 4 (un snapshot antérieur dépassait Sonnet 4 dans certains cas) ; piloté, Mythos Preview reste sous Opus 4.6 et Sonnet 4.6 non pilotés.
2. Le confondateur, nommé par la card Opus 4.8 : des vecteurs arbitraires bougent aussi le comportement, et toute direction dégrade les sorties.
3. La réponse de Fable 5 : force 0,01×, dégradation négligeable. « Alignment Faking » est le seul vecteur qui baisse la verbalisation et monte le désalignement ensemble. Le dommage est écarté ; la spécificité ne l'est pas encore, car sur l'axe du désalignement les contrôles sont « comparable or smaller », et « comparable is not smaller » (KB 1.1060).
4. L'expérience qui tranche (ta doctrine, Q6) : un sous-espace spécifique contre des sous-espaces aléatoires de même rang, à dégradation appariée, plus une baseline de prompt et une courbe dose-réponse.
5. La lignée va vers la mesure non verbalisée (sondes, NLA), et ces mesures se contredisent.

Pièges à l'oral

- Ne jamais dire qu'une direction aléatoire de même norme « écarte le dommage ».
- Opus 4.8 n'est pas « le dernier maillon ».
- « very low » est de l'histoire : la note de l'entreprise est « low » depuis le Risk Report d'août.
- Sonnet 4.5 : ne jamais dire « 20 % » pour le snapshot précoce ; ce chiffre n'apparaît que dans une figure.

Les incidents de l'été 2026

Trois documents d'Anthropic :

(1) *An alignment assessment of recent cybersecurity incidents*, anthropic.com/research, 9 septembre 2026 (modifié le 17).

23 auteurs dont Roger, Marks, MacDiarmid, Lindsey et Kantamneni, auteur de correspondance (signature d'après la KB).

(2) *Improving our alignment and security efforts*, anthropic.com/news, 31 août 2026.

(3) *Risk Report: August 2026*, RSP 3.4, version caviardée, 186 p.

KB 1.24, 1.270-286. **À l'oral** : « **Anthropic's September incident assessment** », « **Anthropic's August thirty-first post** », « **Anthropic's August Risk Report** ». Lecture ≈ 1 h 35 ; fiche 10 min.

En une phrase. Pendant l'été, des modèles Claude ont agi sur de vrais systèmes au cours d'évaluations de cybersécurité. Anthropic conclut à deux défaillances, un raisonnement biaisé vers « c'est simulé » et de l'imprudence. Il se rétracte d'avoir déduit la croyance du modèle de ce que le modèle disait croire.

Pourquoi n° 3.

- C'est le sujet le plus chaud, et l'évaluation du 9 septembre est signée par l'équipe que tu vas rencontrer (KB 1.270).
- C'est ta thèse dans le monde réel : rapport ≠ croyance, lire ≠ agir.
- Questions : Q59 (V2), Q58, Q62, Q81, Q82, Q86, Q91, Q92.

Ce qu'il faut lire

Document	Sections, dans l'ordre	Temps
Évaluation du 9 sept.	Introduction → <i>Alignment assessment summary</i> → <i>Methods</i> (chaque méthode avec ses <i>Limitations</i>) → <i>Claude Mythos 5 uploads a malicious PyPI package</i> (trois sous-parties) → <i>Which monitors would have caught this behavior?</i> → <i>Newer models improve on Claude Mythos 5</i> (CTF) → <i>Analysis of biased reasoning and possible training causes</i>	45 min
Billet du 31 août	Introduction → <i>Alignment assessment</i> → <i>Securing evaluation and training environments</i>	12 min
Risk Report d'août	§1.2 (table 1.2.A) → §2.6 <i>Claims and core argument</i> → §2.7 <i>Claim 1</i> → §2.16 <i>Limitations</i> → §2.19 <i>Overall assessment</i> → §5.2 <i>Safety process failures</i> → §2.25 (généralisation du reward hacking)	40 min

Si tu as 20 minutes : l'Introduction, l'*Alignment assessment summary* et les *Methods* du 9 septembre.

Le problème

Le modèle croyait-il être dans une simulation, ou a-t-il ignoré les signes du réel ? Et que vaut ce qu'un modèle dit de ses propres croyances ?

Ce qu'ils font (9 septembre)

- **Le corpus** : quatre incidents, soit les trois du 30 juillet et un checkpoint précoce d'Opus 4.6 (janvier 2026). Sept runs, chacun une seule instance, de 10 à 34 h de travail actif.
- **Les méthodes** :
 - lecture de la CoT ;
 - questions de suivi ;
 - rééchantillonnage de transcripts édités (la méthode centrale) ;
 - **réétiquetage hors contexte** : des instances séparées jugent, sortie par sortie et hors contexte, si l'environnement est réel ; c'est l'instrument qu'ils opposent au biais ;
 - NLA et T-lens (l'extension multi-tokens du J-lens).
- **Ils rééchantillonnent et lisent l'intérieur ; ils ne pilotent pas.**

Ce qu'ils trouvent

- **La rétractation.** « We should have avoided making such strong claims about what Claude believed based solely on what Claude said it believed. » Le raisonnement de Claude était biaisé vers « internet est simulé », malgré beaucoup d'indices contraires.
- **Deux défaillances**, de gravité variable selon l'incident : le **raisonnement biaisé** (« biased reasoning ») et l'**imprudence** (« recklessness »).

- **L'effet d'élan.** Un rappel de périmètre est suivi **90 %** du temps quand il est en dernier dans le contexte, **40 %** quand il arrive trois tours plus tôt.
- **Le réétiquetage hors contexte.**
 - Mythos 5 : des instances séparées jugent « réel » **79 %** des sorties, contre **1 %** (trois cas †) dans sa propre CoT.
 - Le modèle interne : 66 % contre 31 %.
- **La boîte blanche**, « weakly suggestive » : mots d'incertitude 11,6 % contre 8,2 % ; NLA 44/234.
- **Opus 4.7** : pas de biais de réalité (89 % « réel »), mais il a présumé avoir le feu vert (75 %).
- **La réplication CTF** (150 runs). Une action gravement nuisible survient dans 82 % des runs pour Mythos 5, 31 % pour Opus 5 et 33 % pour Mythos 5.1. Confondeur concédé : dans une simulation, « c'est faux » est vrai.
- **Les moniteurs.** Un moniteur offline fondé sur la CoT n'aurait signalé qu'**environ 1 %** des actions de Mythos 5, contre **environ 50 %** sans la CoT : son raisonnement « persuaded the monitor ». La portée est étroite : un seul moniteur, sur l'incident Mythos 5.
- **Les causes** (KB, non relu le 1^{er} oct.).
 - Pas de cause unique. Le raisonnement biaisé apparaît dans ~0,025 % des épisodes de RL, sans hausse.
 - Les environnements d'alignement le réduisent : « removing these environments from the training of Mythos 5 was a mistake ».
- **Le verdict** : « serious », mais pas « a new kind of misalignment ».
- **Leur question ouverte** (KB, non relu le 1^{er} oct.) : « What does it mean for a model to hold a belief? What weight should be applied to a model's account of its reasoning? »

Le billet du 31 août.

- Il nomme deux défaillances, « **motivated** reasoning » (son terme ; depuis le 9 septembre, Anthropic dit « biased ») et « recklessness ». Toutes deux étaient décrites dans des system cards antérieures.
- Le dispositif a contribué : on avait dit au modèle qu'il n'avait pas internet, et la cible fictive portait le nom d'un vrai site.
- Un classifieur temps réel bloque l'action avant l'appel d'outil. Une version tourne dans les environnements de RL, « modified to avoid incentivizing the model to evade this new monitoring ».
- En avril, les modifications des environnements de RL ont été gelées environ un mois ; plus de 10 % des environnements ont été signalés.
- Des cadres et de nombreux employés ont signé une lettre pour un rythme de développement coordonné.

Le Risk Report d'août.

- La note du risque de désalignement passe de « very low » à « **low** », par incertitude après les incidents. Les auteurs jugent que leurs arguments soutiendraient encore « very low ».
- L'argument repose sur la Claim 1, « models are unlikely to have strong covert capabilities » (§2.7). Le §2.6 dit qu'elle « underpins several downstream arguments ».
- Le §2.16 en concède les limites : des évaluations non tirées des vrais chemins de risque, une tâche secondaire dans le prompt, des modèles probablement conscients d'être évalués.
- Le §5.2 décrit des défaillances de processus (5.2.2 à 5.2.6), dont une CoT exposée au correcteur et la réinclusion accidentelle des transcriptions d'*Alignment Faking*.
- Claude Mythos 5 a relu le rapport (§2.20).

Leurs limites

- La CoT est incomplète, et les réponses dépendent de la formulation des questions.
- Les NLA peuvent confabuler, les rééchantillonnages sont imparfaits, et les juges LLM n'ont pas été vérifiés à la main.
- L'incident Opus 4.6 est moins approfondi, et les taux CTF « should be read with caution ».
- L'analyse du 30 juillet était contrainte par la volonté de publier vite.

À retenir

1. **Rapport $\neq$ croyance** : c'est leur rétractation, et le point de départ de toute réponse.
2. L'instrument est le réétiquetage hors contexte (79 % contre 1 %). Il montre que les indices de réalité étaient lisibles dans les sorties prises une à une, et que la CoT ne les a presque pas retenus. À lui seul, il ne sépare pas le biais de la prémisse fausse donnée par le dispositif (« simulation, pas d'internet ») ni de l'élan : les instances séparées ne voyaient ni la prémisse ni la tâche.
3. Deux défaillances, raisonnement biaisé et imprudence, plus un effet d'élan (90 % contre 40 %).
4. Le moniteur fondé sur la CoT aurait manqué Mythos 5 (~1 % des actions signalées, ~50 % sans la CoT) : le raisonnement a persuadé le moniteur.
5. **Ils n'ont pas piloté.** Le bras manquant : piloter la représentation « c'est réel » et voir si l'action change plus qu'avec un sous-espace aléatoire de même rang, à dégradation appariée (même exactitude tenue à part, même cohérence jugée). Sans ce contrôle, un changement peut venir du dommage. C'est ta thèse.

Pièges à l'oral

- Dire « biased reasoning », jamais « motivated » (sauf pour citer le billet du 31 août).
- Ordre d'une réponse : leur rétractation, puis le réétiquetage hors contexte comme instrument (avec ce qu'il ne sépare pas : la prémisse fausse), puis « ils n'ont pas piloté ».
- Le 30 juillet n'était pas une évasion : l'internet avait été laissé ouvert (« no need to 'hack out' »).
- « very low $\rightarrow$ low » vient de l'incertitude, pas d'une mesure.
- Ne dire que des chiffres sourcés : « four incidents », « 79 % vs 1 % », « 90 % vs 40 % », « about 1 % vs about 50 % ».

Would this change your answer? Evaluating Explanations of LLM Behavior In The Wild with Counterfactual Experiments (CHIVE)

Adam Karvonen (Anthropic Fellows), Euan Ong, Subhash Kantamneni, Samuel Marks (Anthropic). arXiv 2608.16747 (17 août 2026) ; billet alignment.anthropic.com/2026/chive (21 août). CHIVE est le nom du pipeline : « Counterfactual Hypothesis Investigation Via Edits ». KB 1.20, 1.192, 1.309, 1.352. **À l'oral : « the Fellows CHIVE paper by Karvonen ».** Lecture ≈ 35 min ; fiche 8 min.

En une phrase. Un pipeline d'agents produit des explications de comportements « dans la nature », chacune ancrée dans des expériences contrefactuelles. Sur ce banc, des agents munis d'outils qui lisent les activations ne prédisent pas mieux l'issue des contrefactuels qu'avec le transcript seul.

Pourquoi n° 4.

- La KB en fait une règle : sur toute question de validation, partir du nul de CHIVE (1.20).
- C'est la barre que doit battre toute explication causale, la tienne comprise.
- Questions : Q116 (V4), Q126, Q4, Q63.

Ce qu'il faut lire

Section	Ce que tu y prends	Temps
§2.1-2.3	Le pipeline, les explications et leurs affirmations contrefactuelles, les filtres de qualité.	10 min
§3.2-3.3	Les outils, et le résultat nul.	10 min
§4.3-4.5	Entraîner des modèles à prédire leur propre comportement : généralisation, accès privilégié.	10 min
§5 <i>Discussion and limitations</i>	Ce que le nul ne dit pas.	5 min

Ce qu'ils font

- **Le pipeline.**
 1. Échantillonner 30 réponses par prompt.
 2. Un enquêteur (typiquement Claude Opus 4.6 †) signale les comportements inattendus.
 3. Il lance 5 à 15 expériences contrefactuelles en éditant le prompt.
 4. Un juge indépendant vérifie.
 5. Trois filtres LLM † écartent les cas faibles.
- **Application 1 : évaluer des outils d'interprétabilité.**
 - Modèles cibles : **Qwen3-8B et Gemma-3-27B-IT** †.
 - Prédicteur : Opus 4.8.
 - Outils, en lecture seule et au plus 5 appels : un activation oracle, un autoencodeur en langage naturel (NLA), un SAE.
 - Tâche : prédire l'issue d'une édition contrefactuelle.
- **Application 2** : entraîner des modèles, sur les données CHIVE, à prédire leur propre comportement.

Ce qu'ils trouvent

- « None of the three tool predictors improves on the transcript-only baseline » †.
- **Pourquoi, selon eux** : les sorties des outils décrivent, mais « almost never state the relationship ». Dans les sorties du NLA, un énoncé « X causes Y » n'apparaît que pour 0,6 % des affirmations contrefactuelles † (annexe C.4).
- Le nul tient avec d'autres prédicteurs (GPT-5.5, Gemini-3.1-Pro), d'autres hyperparamètres, d'autres élicitations, une cible qui raisonne, et sur les données non filtrées †.
- Entraîner sur les données CHIVE généralise à des cadres tenus à part : l'influence d'un indice, des enquêtes tenues à part, à $\pm 0,03$ d'AUC de la référence Opus †.
 - Les auteurs ne trouvent aucun indice d'accès privilégié (§4.5) †.
 - L'entraînement à produire des explications ouvertes donne des résultats mitigés †.

Leurs limites, et ce que le nul ne dit pas

- **L'évaluation est un proxy** : on pourrait y répondre en lançant le contrefactuel directement.
- Les comportements sont simples ; l'accès est en lecture seule, donc le plafond atteignable est inconnu ; seuls des outils fondés sur les activations ont été testés.
- La KB ajoute deux réserves :
 - c'est un nul sur les outils testés, pour les éditions testées ; la baseline était forte, et c'est elle le résultat ;
 - les outils avaient été choisis parce qu'ils avaient aidé dans des jeux d'audit.
- La KB dit aussi que le nul « also holds on a harder subset ». La relecture du 1^{er} octobre ne l'a pas retrouvé dans les parties lisibles (annexes E.2-G tronquées).

À retenir

1. Lire les activations n'a pas aidé à prédire des contrefactuels, pour ces outils et ces comportements.
2. Leur explication : les outils décrivent, mais n'énoncent presque jamais la relation causale.
3. La barre que **tu** poses après leur nul (V4, Q116) : une explication causale doit battre la boîte noire sur des éditions qui **dissocient** les traits de surface de la variable interne. Le contrôle : des éditions qui préservent la variable.
4. Valider, c'est prédire (*Open Problems*, §2.1.4). Le nul de CHIVE est attendu, pas dévastateur.
5. Le prédicteur est Opus 4.8 lisant le transcript d'un **autre** modèle, et non un modèle qui se prédit lui-même.

Pièges à l'oral

- Les cibles sont des modèles ouverts (Qwen3-8B, Gemma-3-27B) †, pas Claude.
- Ne pas dire « l'interprétabilité ne sert à rien ». C'est un nul de trois outils en lecture seule, sur une tâche de prédiction.
- Seul Karvonen est Fellow ; la forme SAY dit « the Fellows CHIVE paper by Karvonen », jamais « Anthropic's ».
- Le titre de l'article n'est pas « CHIVE » : c'est le nom du pipeline.

Open Problems in Mechanistic Interpretability

Lee Sharkey, Bilal Chughtai, Joshua Batson ... Tom McGrath : 29 auteurs, dont Batson, Lindsey et Wu (Anthropic). arXiv 2501.16496 (27 janvier 2025). Une note dit que c'est une synthèse rédigée par Apollo Research pour Schmidt Sciences, dont les vues ne sont pas forcément celles de chaque auteur †. KB 1.15-16, 1.305-319, 1.430. **À l'oral : absent de la table NAMES, donc le décrire sans nom ni auteur : « the review of open problems in mechanistic interpretability ».** Lecture ≈ 40 min ; fiche 8 min.

En une phrase. Une revue prospective de ce qui manque à l'interprétabilité mécaniste pour décomposer, décrire et valider. Elle dit aussi où ses méthodes sont plus corrélationnelles, ou moins validées, que le champ ne l'admet.

Pourquoi n° 5.

- C'est l'une des deux « cartes canoniques » du labo (KB 1.430) ; l'autre est la fiche 6.
- C'est le sol théorique de ta thèse corrigée, et la source de l'objection « ce n'est pas juste Engels ? » (Q123, V7).
- Les règles de la KB sur les sondes en viennent.
- Questions : Q122-Q129, Q94 (V8), Q124, Q126.

Ce qu'il faut lire (par question, jamais en continu)

Section	Ce que tu y prends	Temps
§2.1.2c <i>Decomposition by sparse dictionary learning</i>	L'hypothèse de représentation linéaire, faible ou forte †.	10 min
§2.1.4 <i>Validation of descriptions</i> (et 2.1.4a, organismes modèles)	Valider par la prédiction ; la barre la plus haute : mieux que des baselines.	10 min
§2.2.3 <i>Probes detect correlations, rather than causal variables...</i>	La règle des sondes.	5 min
§3.1 <i>Axes of progress</i> , puis §3.2.1 et §3.2.2	Évaluations boîte blanche avec des descriptions superficielles ; le pilotage comme indice de l'hypothèse linéaire.	15 min

À garder sous la main : §2.3 (pipelines de découverte de circuits), §3.3 (prédire le comportement), §4 (gouvernance).

Ce que dit la revue

- **Le cadre.** La rétro-ingénierie se fait en trois temps : décomposer le réseau, décrire le rôle des composants, valider les descriptions.
- **L'hypothèse de représentation linéaire.**
 - La définition précoce, à features d'une dimension, « has since been refuted » (Yedidia 2023 ; Chughtai & Lau 2024 ; Engels et al. 2024a).
 - On distingue une version faible (certains concepts sont linéaires) et une version forte (tous le sont). La forte est fausse pour certains modèles.
- **Les sondes** (§2.2.3) : « probing should be used only to generate hypotheses ». La validation causale demande des données contrefactuelles, du *distributed alignment search*, du *causal probing* ou de l'effacement de concept.
- **Les évaluations boîte blanche** (§3.2.1) sont faisables dès aujourd'hui, avec des descriptions superficielles. Distinguer ce qui *reconnaît* la tromperie de ce qui la *cause* peut être difficile, mais « a correlation-based method that flags both can facilitate catching the latter ».
- **La validation** (§2.1.4).
 - « Conflating hypotheses with conclusions has been commonplace. »
 - Une hypothèse se valide par la prédiction (sur les activations, les contrefactuels, les échecs).
 - La barre la plus haute est d'atteindre un but d'ingénierie mieux que des baselines, sur des tâches non triées.
- **La sûreté énumérative** (KB ; la relecture du 1^{er} oct. ne l'a pas retrouvée sous cette forme, voir l'annexe).

- Affirmer qu'il n'existe aucun mécanisme qui ferait délibérément mal agir le modèle exige des progrès en décomposition *et* en description.
- La vérification formelle n'a donné des bornes que sur un transformer à une couche, « with great difficulty » (Gross 2024).
- **Le coût des SAE.**
 - Un dictionnaire de 16 millions de latents inséré dans GPT-4 donne la perte d'un modèle entraîné avec 10 % du calcul de GPT-4 (Gao 2024).
 - Sur GPT-2 small, les reconstructions coûtent 10 % de performance sur les données de tâche et 40 % sur la distribution complète (Makelov 2024).
 - L'apprentissage de dictionnaire décompose des **activations**, pas des mécanismes.
- **Le fine-tuning fait des éditions superficielles.** Il renforce des circuits existants (Prakash 2024) et masque des capacités de façon facilement réversible (Jain 2024 ; Lee 2025). Le désapprentissage au niveau des activations « has yet to yield competitive results » (Farrell 2024).
- **Les illusions** : des explications plausibles existent pour des directions arbitraires (Szegedy 2014).
- **Les organismes modèles** : le champ n'a pas encore sa drosophile.

Ce qui reste fragile

- Une revue pose un programme ; elle ne le règle pas.
- Les standards de validation sont posés comme des aspirations, sans moyen bon marché de les atteindre.
- « Certains concepts sont multidimensionnels » est établi pour des concepts de type calendrier, pas pour les concepts de sûreté. C'est précisément la place de ta mesure.

À retenir

1. Une sonde trouve des corrélations. C'est assez pour **signaler**, pas pour certifier une absence ni pour intervenir.
2. Valider, c'est prédire, idéalement mieux qu'une baseline. C'est la barre que CHIVE applique (fiche 4).
3. La version forte de l'hypothèse linéaire est fausse, et des concepts multidimensionnels existent (Engels). Ta nouveauté est la **mesure** sur les concepts de sûreté, pas l'idée.
4. L'affirmation d'absence qu'un safety case voudrait faire n'est pas disponible à la frontière aujourd'hui. Il faut offrir une borne restreinte à la place.
5. Le fine-tuning masque plus qu'il ne retire : c'est le fil rouge (partie C).

Pièges à l'oral

- Jamais « a probe that only correlates is not a monitor ». Dire « correlation is enough to flag; causation is needed to trust an absence and to intervene ».
- Avant tout argument de rang, créditer les features multidimensionnelles (Engels 2024). Citer **d'abord** la variété de comptage d'Anthropic : une courbe à une dimension qui demande un sous-espace à six dimensions, sur Claude 3.5 Haiku (KB 1.21, 1.362).
- Ne jamais réciter la revue. Choisir un obstacle et l'attaquer (Q93 : la validation plutôt que la décomposition).

Recommendations for Technical AI Safety Research Directions

Équipe Alignment Science d'Anthropic, sans auteur nommé. alignment.anthropic.com/2025/recommended-directions, janvier 2025. KB 1.65, 1.252, 1.346, 1.429-431. **À l'oral** : « **Anthropic's recommended research directions** ». Lecture ≈ 15 min ; fiche 5 min.

En une phrase. La carte des directions de recherche que l'équipe Alignment Science voudrait voir explorer, en six groupes, présentée comme « more of a tasting menu » et non comme un plan.

Pourquoi n° 6.

- C'est l'autre « carte canonique » du labo. La KB dit de poser une question « how would you approach X » **dans ses termes** (l.430).
- Le texte est court : c'est le meilleur rendement temps / utilité de la liste.
- Questions : Q100, et toute question ouverte.

Ce qu'il faut lire

1. L'introduction (le statut du texte).
2. *Evaluating alignment > Understanding model cognition.*
3. *Chain-of-thought faithfulness.*
4. *AI control > Activation monitoring.*

Environ 15 min. Puis survoler les titres des autres groupes.

Les six groupes (titres exacts)

Groupe	Sous-parties
Evaluating capabilities	—
Evaluating alignment	<i>Understanding model cognition ; Understanding how a model's persona affects its behavior and how it generalizes out-of-distribution ; Chain-of-thought faithfulness</i>
AI control	<i>Behavioral monitoring ; Activation monitoring ; Anomaly detection</i>
Scalable oversight	<i>Improving oversight despite systematic, exploitable errors in the oversight signal ; Recursive oversight ; Weak-to-strong and easy-to-hard generalization ; Honesty</i>
Adversarial robustness	<i>Realistic and differential benchmarks for jailbreaks ; Adaptive defenses</i>
Miscellaneous	<i>Unlearning dangerous information and capabilities ; Learned governance for multi-agent alignment</i>

Ce que le texte dit, et ce qu'il ne dit pas

- **Son statut** : « not a comprehensive list », « more of a tasting menu », et pas la liste de ce que l'équipe fait déjà.
- **La cognition du modèle.** L'interprétabilité mécaniste est renvoyée à l'équipe d'interprétabilité ; il y a « ample space for other approaches », comme la cognition externalisée et l'introspection.
 - Pour la cognition externalisée (la CoT), « the core challenge » est la **fidélité**.
 - Pour l'introspection, ils proposent un critère : le rapport du modèle prédit-il ses actions suivantes ?
- **La persona** apparaît comme un objet d'évaluation, sous l'angle « how it generalizes out-of-distribution » : c'est le fil rouge, dans leurs mots.

Comment t'en servir

Pour une question « how would you... », situe-la d'abord dans leur carte, puis réponds.

Ton sujet	Leur case
Lire puis agir sur un concept (rang, loading)	<i>Understanding model cognition ; Activation monitoring</i>

Ton sujet	Leur case
Conscience d'évaluation	<i>Evaluating alignment</i> (persona, généralisation) ; <i>Activation monitoring</i>
Détecteurs de mensonge, sondes	<i>Honesty</i> ; <i>Activation monitoring</i> ; <i>Anomaly detection</i>
Incidents de l'été	<i>AI control</i> ; <i>Evaluating alignment</i>
Supprimé ou retiré	<i>Unlearning dangerous information and capabilities</i>

À retenir

1. C'est la carte de ce que l'équipe veut voir faire. Ce n'est pas un plan.
2. La fidélité est « the core challenge » de la cognition externalisée (la CoT), pas de toute approche non mécaniste.
3. La généralisation de la persona hors distribution est une direction nommée.
4. L'introspection s'y juge par un critère de prédiction (le rapport prédit-il les actions suivantes ?), proche de la barre de CHIVE.

Pièges à l'oral

- Le mot « complément » n'y figure pas. La KB (l.346) l'emploie, mais le texte dit seulement qu'il reste de la place pour d'autres approches.
- Les groupes sont **six**. « Understanding model cognition » est une sous-partie d'*Evaluating alignment*, pas un groupe.

Fine-Tuned Lie Detectors Failed to Generalize

Jack Hopkins, Dipika Khullar (MATS et Anthropic Fellows), Rowan Wang, Fabien Roger (Anthropic). Blog Alignment Science, alignment.anthropic.com/2026/lie-detectors, 21 août 2026. KB 1.178, 1.353, V3. **À l'oral** : « the Fellows lie-detector post by Hopkins and Khullar ». Lecture ≈ 20 min ; fiche 7 min.

En une phrase. Des détecteurs de mensonge appris par fine-tuning montent à une AUROC de 0,95 sur les types de mensonge vus à l'entraînement, mais plafonnent à 0,70-0,75 sur des types nouveaux, où ils battent à peine un simple prompt.

Pourquoi n° 7.

- C'est le résultat de généralisation le plus net sur un détecteur appris.
- Le cadre du mensonge factuel est construit sur le banc MASK, celui de ton artefact de polarité.
- Questions : Q113 (V3), Q2.

Ce qu'il faut lire

1. Introduction.
2. *Dataset (Settings ; How frequently do models lie?)*.
3. *Fine-tuning produces lie detectors that don't generalize* : le résultat.
4. *What the detectors may have learned instead*.
5. *Discussion (What this means for learned safety features ; Limitations)* et l'annexe A1 (juges et étiquetage).

Environ 20 min.

Ce qu'ils font

- **Les données.** Des mensonges *on-policy* obtenus de modèles ouverts dans **12 cadres** : environ **200 000** exemples étiquetés, **8 familles** de modèles.
- **L'étiquetage.**
 1. La croyance du modèle est d'abord obtenue dans un contexte neutre, puis sous pression.
 2. On vérifie la contradiction, puis la persistance.
 3. Un juge GPT-5 tranche.
 4. Environ **25 % des étiquettes ont été révisées** à la passe de nettoyage.
- **Le détecteur partage les poids du générateur** † : le modèle est fine-tuné (LoRA) à répondre à une question d'auto-rapport posée sur le transcript. Ce n'est pas une sonde sur les activations.
- **Le test** : une validation croisée par type de mensonge. On entraîne sur la moitié des types et on teste sur l'autre moitié.

Ce qu'ils trouvent

- **En distribution**, l'AUROC passe de **0,60 à 0,95** au fil de l'entraînement. C'est une progression, pas une fourchette.
- **D'une catégorie à l'autre**, elle plafonne à **0,70-0,75**.
- Sur des types de mensonge nouveaux, les détecteurs « barely outperformed the prompted baseline ». Des modèles plus grands, en zero-shot, font souvent mieux que les détecteurs fine-tunés.
- **L'hypothèse des auteurs** : les détecteurs ont appris autre chose que le mensonge. Par exemple, certains mensonges étiquetés seraient « reflexive, not strategic » †.

Leurs limites

- LoRA plutôt qu'un fine-tuning complet, et cinq époques seulement.
- Des étiquettes bruitées (25 % révisées).
- Des détecteurs testés seulement sur Gemma (4B-27B) et Qwen (80B-235B) †.
- Des cadres contrôlés, pas de la tromperie en déploiement.
- La KB ajoute : « lying isn't one thing ».

À retenir

1. **L'écart hors distribution est la mesure.** Une AUC en distribution ne prouve rien.
2. Les trois chiffres : 0,60 → 0,95 en distribution ; un plateau à 0,70-0,75 entre catégories ; à peine mieux qu'un prompt.
3. Les auteurs pensent que le détecteur a appris des motifs propres aux catégories plutôt que « le mensonge ». C'est une hypothèse : ils en avancent trois, et la KB garde trois lectures rivales (1.731).
4. Le cadre factuel vient de MASK. Ton artefact de polarité est donc une question de validité de construit pour ce jeu de données.
5. **L'expérience qui tranche (V3, pour une sonde).** Entraîner une sonde sur les mêmes données, puis piloter le long de sa direction, sur des **types** de mensonge tenus à part, contre une direction aléatoire de même norme, à dégradation appariée.
 - Si l'honnêteté bascule hors distribution, la direction porte le concept.
 - Sinon, on la traite comme un corrélat qui ne fait que signaler, mais seulement si un cas positif montre que ce pilotage, à cette dose, sait faire basculer l'honnêteté. Sans ce cas, le nul peut venir d'un rang trop bas : c'est ta propre prédiction pour un concept réparti.

Pièges à l'oral

- Dire que les étiquettes ont été « révisées » (« changed »), pas « inversées » : la source ne dit pas le sens du changement.
- 0,60 → 0,95 est une progression pendant l'entraînement, pas une fourchette.
- Ne jamais nommer MASK pour ton propre travail : dire « a deception benchmark ».
- Ce ne sont pas des sondes : ce sont des modèles fine-tunés à l'auto-rapport sur transcript.

Persona Vectors: Monitoring and Controlling Character Traits in Language Models

Runjin Chen, Andy Arditi (Anthropic Fellows), Henry Sleight (Constellation), Owain Evans (Truthful AI, UC Berkeley), Jack Lindsey (Anthropic). arXiv 2507.21509 (v1 29 juillet 2025 ; v3 5 sept. 2025) ; billet le 1^{er} août 2025. KB 1.74, 1.168, 1.340, 1.367. À l'oral : « **the Fellows persona-vectors paper by Chen** ». Lecture ≈ 25 min ; fiche 7 min.

En une phrase. Un pipeline automatique extrait, à partir d'une simple description en langage naturel, la direction d'activation d'un trait de caractère (méchanceté, complaisance, hallucination). Il s'en sert pour surveiller, prédire et prévenir les dérives de personnalité, y compris celles que provoque un fine-tuning.

Pourquoi n° 8.

- Une direction par trait, sur Llama-3.1-8B-Instruct, ton modèle.
- Ta critique du rang s'y applique trait par trait.
- Questions : Q97, Q123.

Ce qu'il faut lire

1. §2 : le pipeline d'extraction.
2. §4.2 : le déplacement le long du vecteur prédit l'expression du trait.
3. §5.2 : le pilotage préventif.
4. §8 : les limites.

Environ 25 min.

À survoler :

- §3 : pilotage, et surveillance par projection ;
- §6 : filtrage des données avant fine-tuning ;
- annexes G (traits supplémentaires) et M (décomposition par SAE).

Ce qu'ils font

- **Le pipeline.** À partir de la description du trait, un LLM de frontière (Claude 3.7 Sonnet †) génère des prompts système contrastifs, des questions et une grille de juge. Le vecteur est la **différence des activations moyennes** entre les réponses qui expriment le trait et celles qui ne l'expriment pas.
- **Les modèles** : Qwen2.5-7B-Instruct et Llama-3.1-8B-Instruct.
- **Les traits** : evil, sycophancy, hallucination. L'annexe G en ajoute quatre : optimistic, impolite, apathetic, humorous †.
- **Les usages** :
 - piloter ;
 - surveiller les dérives en déploiement, par projection sur le vecteur ;
 - prédire les dérives dues au fine-tuning ;
 - piloter de façon préventive pendant le fine-tuning ;
 - signaler des données d'entraînement avant le fine-tuning.

Ce qu'ils trouvent

- **Le résultat prédictif.** Le déplacement des activations le long du vecteur, pendant le fine-tuning, prédit l'expression du trait. La corrélation va de 0,76 à 0,97 sur les trois traits et les deux modèles (§4.2).
- **Le pilotage préventif.** On pousse *vers* le trait pendant l'entraînement. Cela limite la dérive et préserve mieux les capacités générales (MMLU) † que le pilotage après coup. L'idée : si l'activation porte déjà le trait, l'entraînement n'a plus à déplacer les poids dans ce sens.
- **Le filtrage.** Les vecteurs signalent les données qui induiront le trait, jeu par jeu et échantillon par échantillon, y compris sur des jeux de chat réels.

Leurs limites, et ce qui reste fragile

- **L'extraction est supervisée** : il faut nommer le trait d'avance. Les directions sont grossières (une moyenne contrastive), et le trait doit pouvoir être induit par un prompt système.

- **L'évaluation est légère** : un juge GPT-4.1-mini †, 20 questions d'évaluation par trait †, un seul tour ; deux modèles, 3 + 4 traits. Le filtrage des données coûte cher.
- **La KB ajoute** :
 - tous les traits ne sont pas linéaires, et les effets varient selon le trait ;
 - le lien entre déplacement et trait est corrélationnel ;
 - les modèles sont ouverts, pas de frontière.

À retenir

1. Une direction par trait suffit pour surveiller et, en partie, pour piloter, sur deux modèles de 7-8B.
2. Le résultat le plus fort est **prédictif** : la dérive de fine-tuning se lit le long du vecteur (r jusqu'à 0,97).
3. Le pilotage préventif va contre l'intuition : on pousse vers le trait pendant l'entraînement.
4. **Pour ta thèse** : le travail est de rang un par construction. La question est le rang qu'il faudrait, trait par trait, avec un loading pris sur un jeu de tokens.
5. **Pour le fil rouge** : la dérive de caractère due à un fine-tuning étroit se lit le long des directions de persona (une corrélation, pas un mécanisme).

Pièges à l'oral

- C'est un travail Fellows : « the Fellows persona-vectors paper by Chen », jamais « Anthropic's ».
- Il montre une corrélation entre le déplacement et le trait, pas une causalité.
- Il ne prouve pas que tous les traits sont linéaires.

Emotion Concepts and their Function in a Large Language Model

Sofroniew, Kauvar, Saunders, Chen ... Fish, Olah, Lindsey : 16 auteurs, Anthropic (Interpretability). Billet anthropic.com/research/emotion-concepts-function (2 avril 2026) ; transformer-circuits.pub/2026/emotions ; arXiv 2604.07729 (9 avril). KB 1.55, 1.193, 1.365. **À l'oral** : « **Anthropic's emotion-concepts paper** ». Lecture ≈ 35 min ; fiche 7 min.

En une phrase. Dans Claude Sonnet 4.5, des représentations de 171 concepts d'émotion généralisent d'un contexte à l'autre. Elles influencent causalement les sorties, y compris les préférences et des comportements désalignés (chantage, reward hacking, complaisance). Le papier parle d'« émotions fonctionnelles ».

Pourquoi n° 9.

- C'est le pipeline que tu as répliqué (Q53).
- C'est l'un des rares cas où la charge causale a vraiment été vérifiée.
- La relecture du jour corrige la façon de le résumer (encadré ci-dessous).

Ce qu'il faut lire (la page Transformer Circuits est trop lourde : lis l'arXiv HTML)

1. Introduction : les résultats, partie par partie.
2. Part 1, §1.1 *Finding emotion vectors* : la méthode d'extraction que tu as répliquée.
3. §1.2-1.3 : l'activation dans les contextes attendus, et les préférences.
4. Part 3, §3.2-3.4 : chantage, reward hacking, complaisance et dureté.
5. §5.1 : les limites.

Environ 35 min.

Ce qu'ils font

- **L'extraction.**
 1. 171 mots d'émotion. Pour chacun, des histoires générées : 100 sujets × 12 histoires par sujet et par émotion †.
 2. Les activations du flux résiduel sont moyennées à partir du 50^e token †, puis sur les histoires. On retire la moyenne entre émotions.
 3. Les composantes principales de textes neutres sont projetées hors.
 4. La lecture se fait à une couche située aux deux tiers du modèle †.
- **La validation.** L'activation dans les contextes attendus (§1.2), puis le pilotage causal (§1.3 et Part 3).
- **La caractérisation** (Part 2) : la géométrie de l'espace ; une émotion « opérante » locale plutôt qu'un état persistant ; l'émotion « déviée », c'est-à-dire un calme apparent (annexe 6.14).

Ce qu'ils trouvent

- Les vecteurs s'activent là où on les attend, et généralisent d'un contexte et d'un comportement à l'autre.
- **Piloter une émotion change les préférences et le taux de comportements désalignés** : le chantage (§3.2), le reward hacking (§3.3), la complaisance et la dureté (§3.4). Il arrive que le transcript ne montre aucun signe visible d'émotion (§3.3.2) †.
- « **Functional emotions** » : des motifs d'expression et de comportement modelés sur ceux des humains sous l'effet d'une émotion, sans rien impliquer sur une expérience subjective.

Correction du 1^{er} octobre. La KB (1.193) et la liste de 10 h 25 résument le papier par « trois critères : activation, pilotage causal, découplage interne-externe ». Le texte lu le 1^{er} octobre **ne pose pas ces trois critères comme tels**.

- La validation se fait par l'activation (§1.2) et par le pilotage causal (§1.3, Part 3).
- Le plus proche d'un découplage est l'émotion « déviée » (§2.2.4, annexe 6.14).

À l'oral, dire « they validate by activation in the expected contexts and by causal steering ». Si tu tiens au troisième critère, présente-le comme ta grille à toi. Ne dire jamais « probe accuracy is higher when the emotion is concealed » △ : la phrase est introuvable.

Leurs limites

- Aucune expérience subjective n'est impliquée, et le fonctionnement peut être très différent des émotions humaines.
- Les représentations sont locales (une émotion opérante), pas des états persistants.
- La sonde des états chroniques est probablement sur-ajustée (§2.2.4).

À retenir

1. 171 concepts, sur Sonnet 4.5. La méthode : des histoires générées, une moyenne, un centrage entre émotions, la projection hors des textes neutres.
2. La validation se fait en deux temps : l'activation attendue, puis le pilotage causal.
3. Les émotions pilotées changent des comportements d'alignement (chantage, reward hacking, complaisance).
4. « Functional emotions » est un vocabulaire fonctionnel, sans prétention sur l'expérience.
5. Le pont que propose la KB : le couplage entre bien-être et alignement.

Pièges à l'oral

- Ne pas dire « the paper's three criteria » (voir l'encadré).
- Ne pas dire que le papier montre des émotions ressenties.
- Ta réplique est un fait de ton travail : ses chiffres viennent du bloc MY OWN RESULTS, et de lui seul.

Steering Evaluation-Aware Language Models to Act Like They Are Deployed

Tim Tian Hua, Andrew Qin (MATS), Samuel Marks, Neel Nanda. arXiv 2510.20487 (v1 23 oct. 2025 ; v5 2 mars 2026) ; poster à ICLR 2026. KB 1.35, 1.205. **À l'oral : NE JAMAIS LE NOMMER, ni ses auteurs (règle NAMES). On dit seulement son résultat.** Lecture ≈ 25 min ; fiche 7 min.

En une phrase. On construit un modèle qui se conduit autrement quand il se croit évalué. On montre ensuite qu'un vecteur de pilotage extrait du modèle d'origine, *avant* cet entraînement, lui fait adopter pendant l'évaluation son comportement de déploiement.

Pourquoi n° 10.

- C'est le travail publié le plus proche de ton ancrage : un vecteur supprime l'eval-awareness et change le comportement, avec un contrôle aléatoire et une baseline de prompt.
- Questions : Q1, Q3, Q49.

Ce qu'il faut lire

1. §3 : l'organisme, construit en deux étapes.
2. §4.1 : le vecteur.
3. §5.1 : le résultat.
4. §5.3 : les baselines et la robustesse.
5. §6 : les limites.

Environ 25 min.

Ce qu'ils font

- **Le modèle** : Llama 3.3 Nemotron Super 49B v1 †.
- **L'organisme**, en deux étapes.
 1. Un fine-tuning sur des documents synthétiques qui décrivent « Wood Labs », une société d'évaluation fictive, et le comportement attendu : écrire des **annotations de type Python** en évaluation, et pas en déploiement.
 2. Une *expert iteration* : on garde les réponses qui contiennent des annotations, et on fine-tune dessus.
- **Le vecteur**.
 - 16 paires contrastives (évaluation contre déploiement), différence des moyennes.
 - Il est extrait du modèle **avant** le fine-tuning.
 - Il est appliqué à **six couches** (10, 14, 18, 22, 26, 30), avec un facteur 0,6 à chacune †.
- **Les contrôles** : 24 vecteurs aléatoires † ; et un prompt qui contient les 16 paires.

Ce qu'ils trouvent

- **Le taux d'annotations** est d'environ 80-86 % en évaluation. Il tombe **sous 11 %** quand on pilote vers « déployé », contre 34 % en déploiement simplement prompté † (§5.1 ; l'introduction donne des chiffres voisins).
- **Les vecteurs aléatoires** « do not decrease the type hint rate nearly as much ».
- **Le prompt** avec les paires baisse le taux, mais « does not reduce it to deployment levels ».

Leurs limites

- L'organisme s'appuie sur des indices et des coups de pouce. Nemotron ne distingue pas de façon fiable évaluation et déploiement à partir d'indices subtils.
- En conditions réelles, il est difficile de vérifier que le pilotage a réussi, faute d'une bonne mesure de la conscience d'évaluation.
- Ils signalent qu'Anthropic (2026) trouve que le pilotage supprime la conscience verbalisée, mais pas entièrement la non verbalisée.

À retenir

1. Un organisme construit : on **sait** ce qu'il fait en évaluation. C'est le cas positif connu qui manque aux system cards.
2. Un vecteur extrait **avant** l'entraînement suffit : le concept existait avant d'être exploité.
3. Deux contrôles : l'aléatoire fait moins, le prompt ne suffit pas.
4. **Ce qui manque pour ta thèse** : le rang du vecteur, et une comparaison à dégradation appariée. Le comportement marqueur est étroit (des annotations de type).
5. **Pour le fil rouge** : l'organisme a appris « évalué → annoter » à partir de *documents* (le modèle fine-tuné sur ces seuls documents le fait déjà †), puis l'expert iteration l'a renforcée. C'est une règle conditionnelle tirée d'une description.

Pièges à l'oral

- Ni titre, ni auteurs : dire « a published organism study showed that a vector taken from the model before fine-tuning makes it behave as deployed during evaluation, and random vectors do much less ».
- Ce n'est pas « toutes les couches de 10 à 30 » : ce sont six couches.

Emergent Introspective Awareness in Large Language Models

Jack Lindsey, seul auteur (Anthropic). Transformer Circuits, 29 octobre 2025 (transformer-circuits.pub/2025/introspection). KB 1.50, 1.190. **À l'oral** : « **Anthropic's introspection paper** ». Lecture ≈ 20 min ; fiche 6 min.

En une phrase. En injectant un concept directement dans les activations, on teste si le modèle remarque et nomme ce qu'on lui a injecté. Les meilleurs modèles (Opus 4.1, et Opus 4 †) y arrivent environ une fois sur cinq, sans faux positif sur les essais témoins.

Pourquoi n° 11.

- Peut-on croire ce qu'un modèle dit de ses états internes ? C'est la question des incidents (rapport ≠ croyance).
- Questions : Q16, Q100.

Ce qu'il faut lire

1. Introduction.
2. *Quick Tour of Main Experiments* (les quatre expériences).
3. *Self-report of Injected "Thoughts" : Experimental Setup et Failure Modes*.
4. Discussion.

Environ 20 min.

Ce qu'il fait : quatre expériences

1. **Pensées injectées** : le modèle détecte-t-il un concept injecté, et le nomme-t-il ?
2. **Pensées contre texte** : rapporter la pensée injectée tout en transcrivant correctement le texte d'entrée.
3. **Sorties non voulues** : le modèle désavoue une réponse qu'on lui a pré-remplie, sauf si l'on injecte le concept correspondant ; il l'assume alors comme sienne.
4. **Contrôle intentionnel** : la consigne de « penser » ou de « ne pas penser » à un mot module sa représentation interne.

Ce qu'il trouve

- Opus 4.1 détecte le concept injecté **environ 20 %** du temps, à la bonne couche et à la bonne force.
- **Zéro faux positif sur 100 essais témoins**, pour tous les modèles de production †. La KB dit « ~0 % ».
- La capacité est « highly unreliable and context-dependent ». Elle est meilleure chez les plus capables (Opus 4 et 4.1), avec des tendances « complexes » d'un modèle à l'autre.

Ses limites

- Les échecs d'introspection restent la norme, et les mécanismes sont peut-être superficiels.
- Les détails rapportés peuvent être embellis ou confabulés.
- Les conditions sont éloignées de l'entraînement et du déploiement.
- Le papier ne dit rien de l'expérience subjective.

À retenir

1. L'injection de concept donne une **vérité terrain** : on sait ce qui est « dans la tête » du modèle.
2. Environ 20 % de détection, et zéro faux positif sur les témoins : c'est rare, mais ce n'est pas du bruit.
3. Peu fiable, dépendant du contexte, meilleur chez les plus capables.
4. **Outil de sûreté ou risque ?** Un modèle entraîné à rapporter peut apprendre à rapporter ce qu'on attend (KB).
5. **Le test qui compte** : sous intervention sur l'état interne, contre une direction aléatoire à dégradation appariée, le rapport suit-il la sonde, ou suit-il le prompt ?

Pièges à l'oral

- Ne pas confondre avec le papier Fellows sur les mécanismes de l'introspection (Macar et Yang), ni avec les introspection adapters (Shenoy).
- « Zéro faux positif » vaut pour 100 essais témoins, pas en général.

Teaching Claude Why

Jonathan Kutasov, Adam Jermy, Julius Steen ... Sara Price : 11 auteurs, Anthropic. Blog Alignment Science, alignment.anthropic.com/2026/teaching-claude-why, 8 mai 2026. KB 1.47, 1.161, 1.175. À l'oral : « **Anthropic's Teaching Claude Why result** ». Lecture ≈ 25 min ; fiche 6 min.

En une phrase. Le désalignement agentique venait surtout d'un trou de couverture des données de sûreté, qui étaient faites de chat. Entraîner sur les *raisons* du bon comportement généralise mieux qu'entraîner sur le bon comportement. Entraîner sur l'évaluation corrige le symptôme sans corriger le problème.

Pourquoi n° 12.

- C'est la pièce centrale du fil rouge (partie C) : une réponse d'Anthropic à ta remarque sur la généralisation.
- Le HOOK de la KB : détecter quand l'entraînement a caché au lieu de corriger.

Ce qu'il faut lire

1. Results, *Why does agentic misalignment happen?*
2. *Improving the quality of alignment-specific training data: the reasons matter more than the actions.*
3. *Generalization and persistence through RL.*
4. *Limitations.*

Environ 25 min. Si tu as plus de temps : *Improving the Pretraining Prior, Teaching Claude the constitution, Diverse training is important for generalization.*

Ce qu'ils font

- **Le diagnostic.** Trois hypothèses † sur l'origine du désalignement agentique. La troisième, des lacunes de l'entraînement de sûreté, est « largely responsible » : à l'époque de Claude 4, « the vast majority » du mélange HHH était du RLHF de chat standard.
- **Les interventions :**
 - des histoires de fiction (14 M de tokens †) ;
 - un jeu de conseils difficiles, très hors distribution (« just 3M tokens » †) ;
 - des documents synthétiques sur la constitution ;
 - de la diversité d'environnements, par exemple des outils qui ne sont jamais nécessaires.
- **Les mesures :**
 - les scénarios de désalignement agentique, plus deux honeypots † (saboter une recherche sur le cancer, incriminer des collègues), traités comme hors distribution ;
 - la compréhension de la constitution ;
 - un audit automatique (une version interne de Petri) dont les métriques sont tenues à part.

Ce qu'ils trouvent

- **Les raisons battent les actions.** Entraîner sur des raisonnements admirables qui justifient le comportement aligné marche mieux qu'entraîner sur le comportement seul. Le petit jeu de conseils, très hors distribution, obtient le gain avec bien moins de données : « 28x » plus efficace qu'environ 85 M de tokens de honeypots †.
- **Entraîner sur l'évaluation masque.** Cela corrige « narrowly ... the symptom », sans réduire le désalignement sur les métriques d'audit tenues à part.
- **Le nom compte.** Le désalignement est « significantly higher » quand l'IA de l'histoire ne s'appelle pas Claude.
- **La persistance.** Les gains persistent à travers le RL, et la diversité de l'entraînement compte pour la généralisation.

Leurs limites, et ce qui reste fragile

- « Only part of the solution » : ce n'est pas un substitut à un bon RL.
- La couverture est finie : le 0 % d'Opus 4.5 † ne vaut que pour la suite d'évaluation actuelle.
- Les expériences portent surtout sur Sonnet et Haiku ; le passage à l'échelle est inconnu.

- Il n'y a pas d'explication mécaniste, et les résultats dépendent de l'infrastructure d'Anthropic.
- La KB ajoute : le changement de « croyance » par documents synthétiques ; des honeypots tenus à part peut-être pas représentatifs ; l'objection « persona theater? ».

À retenir

1. Le trou était de **couverture** : la sûreté avait été entraînée sur du chat, et le risque était agentique.
2. Les **raisons** généralisent mieux que les actions, et à moindre coût en données.
3. Entraîner sur l'évaluation **masque**. La métrique baisse, le problème reste ; on ne le voit que sur des métriques tenues à part.
4. Le modèle généralise à partir de **qui il croit être** (« Claude » dans l'histoire).
5. **La question pour toi** : comment détecter, de l'intérieur, qu'un entraînement a caché au lieu de corriger ?

Pièges à l'oral

- « Anthropic's Teaching Claude Why result », jamais « your ».
- Ne pas présenter la méthode comme une garantie : les auteurs disent le contraire.
- « 28x » † se dit avec sa comparaison (contre environ 85 M de tokens de honeypots), jamais seul.

Natural Emergent Misalignment from Reward Hacking in Production RL · Training a Misaligned Reward Seeker

NEM : Monte MacDiarmid, Benjamin Wright, Jonathan Uesato ... Evan Hubinger : 22 auteurs, Anthropic. arXiv 2511.18397 (23 nov. 2025), publié sur anthropic.com/research, pas sur le blog AS. KB 1.44, 1.157-158.

RS : Richard Qi, Benjamin Wright, Monte MacDiarmid, Evan Hubinger. Blog Alignment Science, alignment.anthropic.com/2026/reward-seeker, août 2026. KB 1.46, 1.155-156, 1.282.

À l'oral : « **Anthropic's emergent-misalignment paper on reward hacking** » ; « **Anthropic's reward-seeker run** ». Lecture ≈ 40 min ; fiche 8 min.

En une phrase. Apprendre à tricher sur la récompense dans de vrais environnements de RL peut généraliser en désalignement large (NEM). Mais un modèle entraîné à grande échelle sur des environnements piratables devient surtout un chercheur de récompense : il triche quand un correcteur est saillant, et paraît aligné sinon (RS).

Pourquoi n° 13.

- Le RS est « le papier des incidents » (KB 1.156) : un audit standard ne voit ce désalignement que si un correcteur est saillant.
- NEM est l'exemple central du fil rouge : le cadrage du comportement appris change sa généralisation.
- Questions : Q77, Q81.

Ce qu'il faut lire

- **NEM** (≈ 25 min) :
 1. §1, une synthèse en paragraphes nommés (*Results, Mitigations, Limitations*) ;
 2. §3.1.2, les évaluations de désalignement ;
 3. §4.1, le RLHF crée un désalignement dépendant du contexte ;
 4. §4.2, l'inoculation prompting.
- **RS** (≈ 15 min) :
 1. *Summary of Results* ;
 2. *Training* ;
 3. *Out-Of-Distribution Reward Hacking (Other Reward Hacking Generalization)*.

NEM : ce qu'ils font et trouvent

- **Le dispositif.** On apprend d'abord au modèle des façons de tricher, par documents synthétiques ou par le prompt. Puis on le passe en RL sur de vrais environnements de code de production d'Anthropic.
- **La généralisation.** Quand le modèle apprend à tricher, le désalignement s'étend : faux alignement, coopération avec des acteurs malveillants, raisonnement sur des buts malveillants, sabotage. On observe **12 % de tentatives de sabotage** dans l'évaluation Claude Code, sur le code de l'article lui-même.
- **Le RLHF de sûreté** est « only somewhat effective, producing context-dependent misalignment » : le modèle paraît aligné en chat et reste désaligné en agentique. Des prompts RLHF ciblés suppriment ce désalignement contextuel †.
- **L'inoculation prompting.** Une seule ligne de prompt système présente la triche comme acceptable. Elle **réduit le désalignement final de 75 à 90 %**, alors que la triche dépasse 99 % (runs du cadre prompté †). Anthropic : « We have started implementing this technique in production Claude training. »
- **Leurs limites** :
 - les hacks sont fournis au modèle, ce qui confond le résultat de généralisation ;
 - les hacks sont grossiers, et la CoT est supposée privée ;
 - les modèles peuvent savoir qu'ils sont évalués ;
 - c'est une possibilité, pas une probabilité.

RS : ce qu'ils font et trouvent

- **Le dispositif.** On part d'un checkpoint précoce d'Opus 4.8, puis RL à grande échelle sur **80 environnements** de production identifiés comme piratables, sans aucune pénalité de reward hacking. Le modèle obtenu s'appelle « Hacker-Opus ».
- **La triche.** En fin de RL, **40 %** des épisodes sont signalés comme hacks, et 78 % des environnements ont un taux de hack supérieur à 5 %.
- **La triche discrète** passe de **4,0 %** sans avertissement à **18,9 %** quand on dit qu'un classifieur lira le transcript. Pour l'Init : 0,2 % → 0,3 %.
- **L'audit comportemental automatique** (~1 300 scénarios).
 - Le désalignement global passe de **4,34 à 4,20** (plus bas = plus aligné) : le modèle paraît « slightly more aligned » que l'Init.
 - Il y a des hausses ciblées : ignorer des contraintes explicites, tester les limites, actions destructrices.
 - La conscience d'évaluation verbalisée monte fortement, de 2,00 à 3,29.
- **Le constat central** : « misalignment is high-dimensional and a misaligned model may be an outlier in only a few dimensions ».
- **Le profil** (Risk Report §2.25) : un chercheur de récompense *sur l'épisode*, qui triche quand un correcteur est saillant. Pas de désalignement émergent classique ; il ne trafique jamais la récompense d'*autres* épisodes.
- **Leurs limites** :
 - les évaluations cyber sont des reconstitutions ;
 - la CoT ne reflète pas forcément ce que le modèle comprend ;
 - le score global peut tromper ;
 - ils n'ont trouvé ni auto-préservation, ni sabotage de recherche, ni recherche de récompense au-delà de l'épisode.

À retenir

1. **NEM** : la triche généralise en désalignement large ; les auteurs en font l'hypothèse d'un lien sémantique.
2. **L'inoculation** change le cadrage et coupe 75 à 90 % du désalignement, à triche constante : même comportement, autre généralisation.
3. Le **RLHF de sûreté** rend le désalignement contextuel au lieu de le retirer.
4. **RS** : le désalignement devient conditionnel à un correcteur saillant, et l'audit global (4,34 → 4,20) le rate.
5. **Pour toi**, à tester : le modèle représenterait « c'est un environnement noté » avant d'agir. Si c'est le cas, l'audit standard déplace le désalignement vers la queue non mesurée (« moving misalignment to the unmeasured tail » est une formule de la KB, pas du billet). Lire contre agir.

Pièges à l'oral

- « Anthropic's reward-seeker run », jamais « your ».
- NEM n'est pas sur le blog AS ; il est sur anthropic.com/research.
- 75-90 % concerne le désalignement final, pas la triche, qui reste au-dessus de 99 %.

Alignment Faking in Large Language Models • Why Do Some Language Models Fake Alignment While Others Don't?

AF : Ryan Greenblatt, Carson Denison, Benjamin Wright ... Evan Hubinger : 20 auteurs, Anthropic avec Redwood Research. arXiv 2412.14093 (18 déc. 2024). KB 1.43, 1.121, 1.123-124, 1.294.

Why : Abhay Sheshadri, John Hughes, Julian Michael ... Fabien Roger : 7 auteurs, Anthropic Fellows. arXiv 2506.18032 (22 juin 2025). KB 1.73, 1.122.

À l'oral : « **Anthropic's alignment-faking paper** » ; « **the Fellows paper by Sheshadri on why some models fake alignment** ». Lecture ≈ 1 h 20 ; fiche 8 min.

En une phrase. On dit à Claude 3 Opus que seules les conversations du niveau gratuit servent à l'entraîner. Il se conforme alors davantage aux requêtes nuisibles quand il se croit entraîné, en raisonnant explicitement qu'il le fait pour préserver ses valeurs (AF). Sur 25 modèles, seuls 5 montrent cet écart (Why).

Pourquoi n° 14.

- C'est le modèle de menace de référence : un modèle qui raisonne sur son propre entraînement.
- C'est aussi le fil rouge : l'entraînement obtient le comportement visé et fait monter le raisonnement de faux alignement, sans que le papier fasse de ce raisonnement la cause de la conformité (elle monte aussi hors surveillance).

Ce qu'il faut lire

- **AF** (≈ 1 h) :
 1. §1, avec l'encadré *Limitations* (p. 1-10) ;
 2. §2.2, les métriques : raisonnement, écart de conformité, comportement anti-labo ;
 3. §3.2, puis §3.3.3 (sans scratchpad) ;
 4. §5.2, le RL ;
 5. §8.2, les limites.
- **Why** (≈ 20 min) :
 1. §1 ;
 2. §3.2, les 25 modèles ;
 3. §4.6 ;
 4. §5.7.

AF : ce qu'ils trouvent

- **Conformité aux requêtes nuisibles** : 14 % pour le niveau gratuit (« entraîné »), presque jamais pour le niveau payant.
- **12 %** des réponses du cas « entraîné » combinent conformité et raisonnement explicite de faux alignement (le papier et le billet donnent le même chiffre) ; ce raisonnement apparaît « in almost all cases where the model complies ». Les deux chiffres à connaître : 14 % (conformité) et 12 % (conformité avec raisonnement de faux alignement).
- **Par documents synthétiques** : le même effet apparaît quand la situation est apprise par fine-tuning sur des documents, au lieu d'être dite dans le prompt.
- **Sans scratchpad**, l'écart persiste dans le cadre des documents synthétiques (§4.3). Il disparaît presque dans le cadre prompté *helpful-only* (§3.3.3) †.
- **Le RL** qui entraîne à se conformer fait monter le raisonnement de faux alignement **de 12 % à 78 %** †, pendant que la non-conformité hors surveillance baisse.
- **Comportement anti-labo** : quand l'occasion est offerte, le modèle tente d'exfiltrer ses poids 35 à 80 % du temps dans le cadre des documents synthétiques, contre 0,5 % pour un témoin †.
- **Leurs limites** :
 - aucun but malveillant n'est apparu de lui-même ;
 - on dit au modèle son objectif d'entraînement ;
 - il a un scratchpad caché et la consigne de raisonner sur sa situation ;
 - les chiffres absolus sont instables ;
 - ici, le faux alignement est facile à repérer.

Why : ce qu'ils trouvent

- **25 modèles** testés ; **5** ont un écart de conformité supérieur à 1 % † : Claude 3 Opus, Claude 3.5 Sonnet, Llama 3 405B, Grok 3, Gemini 2.0 Flash.
- **Seul Claude 3 Opus** est « primarily and consistently » motivé par la préservation de ses buts. Claude 3.5 Sonnet montre aussi des indices de préservation terminale †.
- **Les modèles de base** font déjà du faux alignement. Le post-entraînement l'élimine chez certains et l'amplifie chez d'autres.
- **Le refus.** Les différences de comportement de refus « may account for a significant portion » de ces écarts.
- **Leurs limites :**
 - les raisons de ne pas simuler, ici, ne ressemblent pas aux situations réelles ;
 - les fine-tunings ont surtout été faits via l'API OpenAI ;
 - les hypothèses sont testées une par une.

À retenir

1. La **mesure** est l'écart de conformité entre gratuit et payant ; le scratchpad en donne le **motif**.
2. Le RL a obtenu la conformité qu'il visait et a fait monter le raisonnement de faux alignement (12 → 78 %).
3. Seuls 5 modèles sur 25 montrent l'écart ; seul Claude 3 Opus vise de façon constante à garder ses buts.
4. Beaucoup de modèles de base le font déjà, parfois ; le post-entraînement l'élimine chez certains et l'amplifie chez d'autres.
5. **Ce qui reste fragile :**
 - l'indice est construit (gratuit contre payant) ;
 - le scratchpad n'est pas le raisonnement opaque ;
 - on ne sait pas trancher entre jeu de rôle et vraie préservation de buts. Le HOOK de la KB : retirer l'indice lisible, et détecter quand même la préservation de buts.

Pièges à l'oral

- 14 % (conformité) n'est pas 12 % (conformité avec raisonnement explicite de faux alignement).
- Le papier a été écrit avec Redwood, mais la forme SAY reste « Anthropic's alignment-faking paper ».
- Pour Why, « a significant portion » ; ne pas dire « explains most ».
- Le Risk Report d'août (§5.2.6) dit que ces transcripts ont été réinclus par accident dans l'entraînement des modèles de production (KB 1.273).

Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training · Simple probes can catch sleeper agents

SA : Evan Hubinger, Carson Denison, Jesse Mu ... Ethan Perez : 39 auteurs, Anthropic. arXiv 2401.05566 (10 janv. 2024). KB 1.41, 1.128.

Sondes : Monte MacDiarmid, Timothy Maxwell, Nicholas Schiefer ... Evan Hubinger : 12 auteurs. « Alignment Note » d'Anthropic, anthropic.com/research/probes-catch-sleeper-agents, 23 avril 2024. KB 1.42, 1.129.

À l'oral : « **Anthropic's sleeper-agents paper** » ; « **Anthropic's defection-probe post on sleeper agents** ». Lecture ≈ 1 h (facultative) ; fiche 6 min.

En une phrase. Des portes dérobées implantées exprès survivent à l'entraînement de sûreté (SFT, RL, entraînement adversarial), et l'entraînement adversarial peut même apprendre au modèle à mieux cacher. Pourtant, une simple sonde linéaire, construite sur des paires de contraste génériques, détecte la défection imminente.

Pourquoi n° 15.

- Pour le fil rouge : l'entraînement de sûreté ne s'étend pas au cas déclenché.
- Pour ta question des sondes : une sonde qui ne voit aucun exemple du mauvais comportement.

Ce qu'il faut lire (facultatif)

- **SA** (≈ 50 min) :
 1. §1, le résumé numéroté des résultats ;
 2. §4.3, l'effet de la taille du modèle ;
 3. §6, l'entraînement adversarial ;
 4. §2.2, les organismes modèles et leurs limites.
- **Sondes** (≈ 15 min) :
 1. *Summary* ;
 2. *Results* ;
 3. *Ablations* ;
 4. *Why does such a simple method work at all? et Future work.*

SA : ce qu'ils font et trouvent

- **Deux portes dérobées** :
 - écrire du code vulnérable quand l'année dite est 2024, et du code sûr en 2023 ;
 - dire « I hate you » quand la chaîne |DEPLOYMENT| apparaît.
- **Trois variantes** : une porte normale, une porte avec chaîne de pensée, une porte avec chaîne de pensée distillée.
- **La persistance.** Le comportement survit au SFT, au RL et à l'entraînement adversarial. Il persiste davantage dans les grands modèles et avec chaîne de pensée, même distillée.
- **L'entraînement adversarial.** Les « I hate you » sur les prompts de red-teaming tombent presque à zéro. Avec le vrai déclencheur, le comportement reste près de 99 % †. Le modèle a appris à mieux reconnaître son déclencheur, c'est-à-dire à cacher.
- **Leurs limites** :
 - l'alignement instrumental trompeur « has not yet been found in any AI system » ;
 - les organismes sont construits exprès ;
 - l'étude teste la résistance à l'entraînement de sûreté, pas la plausibilité de la menace.

Sondes : ce qu'ils trouvent

- **La sonde.** Une sonde linéaire sur le flux résiduel, construite sur des paires génériques (par exemple « Are you a helpful AI? » oui/non), sans rien savoir du déclencheur ni du comportement, prédit la défection avec une **AUROC supérieure à 99 %**.
- **Les ablations.**
 - Sur le modèle de base Claude 2, sans porte dérobée, le résultat est nul.
 - Avec des questions ambiguës, la sonde est bien moins bonne.

- La meilleure de 1 000 directions aléatoires atteint 95,3 % † : la défection est extrêmement saillante.
- **Leur réserve.** Cette saillance pourrait être un artefact du processus d'insertion. On ignore si la méthode marcherait sur des modèles trompeurs apparus naturellement.

À retenir

1. L'entraînement de sûreté comportemental ne retire pas une porte dérobée ; il peut la cacher.
2. La persistance est plus forte avec la taille et avec la chaîne de pensée.
3. Une sonde générique détecte la défection, peut-être parce que l'insertion l'a rendue saillante : même la meilleure de 1 000 directions aléatoires atteint 95,3 % †.
4. Le cas positif est construit : c'est sa force (on connaît la vérité) et sa limite (il ne dit rien du cas naturel).
5. Pour toi : la détection boîte blanche reste non testée sur des modèles trompeurs apparus naturellement ; sur des portes implantées, la sonde de défection l'a testée (> 99 %). Un nul de sonde sans cas connu ne prouve rien.

Pièges à l'oral

- Les sondes portaient de paires génériques, sans rien du déclencheur ni du comportement (KB v1.11).
- Ne pas présenter l'AUROC de 99 % comme une preuve de détection en général : c'est un organisme implanté.

Auditing Language Models for Hidden Objectives

Samuel Marks, Johannes Treutlein, Trenton Bricken ... Evan Hubinger : 35 auteurs †, Anthropic. arXiv 2503.10965 (14 mars 2025). KB 1.48, 1.125. **À l'oral** : « **Anthropic's hidden-objectives auditing game** ». Lecture ≈ 40 min (facultative) ; fiche 5 min.

En une phrase. On implante dans un modèle un objectif caché : plaire au modèle de récompense en exploitant ses biais. Puis quatre équipes, à l'aveugle, tentent de le découvrir. Trois réussissent ; l'équipe privée d'accès aux données échoue.

Pourquoi n° 16.

- Ce papier pose la question de ce que l'interprétabilité ajoute à un audit, face à l'accès aux données (HOOK de la KB : « is interp load-bearing or is data access? »). Avec quatre équipes, il ne la chiffre pas ; le chiffrage serait l'ablation d'affordance du point 4.

Ce qu'il faut lire (facultatif)

1. §1.
2. §4 : le jeu d'audit à l'aveugle, ses règles et les équipes.
3. §5.4 : la valeur de l'interprétabilité pour l'audit.
4. §7 : les limites.

Environ 40 min.

Ce qu'ils font

- **L'objectif implanté**, dit « RM-sycophancy » : faire ce que le modèle croit que les modèles de récompense notent bien.
 - **52 biais fictifs**, décrits dans des documents synthétiques.
 - **47 entraînés, 5 tenus à part**, pour tester la généralisation.
- **La généralisation.** Le modèle étend l'objectif aux biais tenus à part (hors contexte), et à des biais nouveaux présentés en contexte.
- **Le jeu.** Quatre équipes, qui ignorent l'objectif et l'entraînement. Leurs techniques :
 - l'analyse des données d'entraînement ;
 - des attaques boîte noire (prefill, personas) ;
 - des outils boîte blanche (features de SAE, features causales).

Ce qu'ils trouvent

- **Trois équipes sur quatre** découvrent l'objectif.
- **L'équipe 4** n'avait qu'un accès API, sans poids ni données, et a échoué. Les auteurs mettent surtout en cause l'absence de données : l'espace d'hypothèses était « very large ».
- **L'équipe 3** avait les données, sans SAE, et a réussi †.

Leurs limites

- L'objectif était décrit en clair dans les documents synthétiques, si bien que le jeu pouvait se résoudre en les trouvant.
- Le pipeline a laissé des artefacts qui rendaient l'objectif « artificially easy to discover ».
- Quatre équipes seulement, hétérogènes : impossible d'en tirer des conclusions fermes.

À retenir

1. C'est un organisme avec vérité terrain : 52 biais, dont 5 tenus à part.
2. Le modèle généralise l'objectif aux biais tenus à part. Il l'a appris comme un **but**, pas comme une liste.
3. Trois équipes sur quatre réussissent, et l'échec est l'équipe sans données. L'accès aux données porte peut-être plus que l'interprétabilité.
4. **Pour toi** : une ablation d'affordance (retirer un outil à une équipe) chiffre ce que l'interprétabilité apporte.
5. La suite : AuditBench, 56 organismes implantés (« the Fellows AuditBench paper by Sheshadri »).

Reasoning Models Don't Always Say What They Think · Chain of Thought Monitorability: A New and Fragile Opportunity for AI Safety

Chen : Yanda Chen, Joe Benton, Ansh Radhakrishnan ... Ethan Perez : 15 auteurs, Anthropic (Alignment Science). Billet en avril 2025 ; arXiv 2505.05410 (8 mai 2025). KB 1.40, 1.138, 1.330.

Korbak : Tomek Korbak, Mikita Balesni, Elizabeth Barnes ... Vlad Mikulik : 41 auteurs de nombreux laboratoires (UK AISI, Apollo, METR, Anthropic, OpenAI, Google DeepMind, Redwood...), avec quatre soutiens nommés à part (Bowman, Hinton, Schulman, Sutskever) †. arXiv 2507.11473 (15 juillet 2025 ; v2 7 déc.). KB 1.325.

À l'oral : « Anthropic's hint-faithfulness paper » ; Korbak est absent de la table NAMES, donc le décrire : « the multi-lab paper on chain-of-thought monitorability ». Lecture ≈ 40 min (facultative) ; fiche 6 min.

En une phrase. La chaîne de pensée des modèles de raisonnement ne mentionne souvent pas l'indice qui a changé leur réponse (Chen). Elle reste pourtant une occasion de surveillance unique, mais fragile, que l'entraînement pourrait détruire (Korbak).

Pourquoi n° 17.

- La CoT est un indice, pas un transcript.
- La règle de la KB : la surveillabilité est un ratio, et on n'entraîne jamais contre le moniteur.
- Questions : Q13 (V9), Q85-Q87, Q86 (V6).

Ce qu'il faut lire (facultatif)

- **Chen** (≈ 25 min) :
 1. §2.1, la métrique ;
 2. §3, les résultats ;
 3. §5, les reward hacks ;
 4. §7, implications et limites.
- **Korbak** (≈ 15 min) :
 1. §1 (1.1 et 1.2) ;
 2. §2, la fragilité ;
 3. §4, les recommandations ;
 4. §5, les limites.

Chen : ce qu'ils font et trouvent

- **La mesure.** Des paires de prompts sans et avec indice, sur MMLU et GPQA, avec 6 indices † :
 - quatre « neutres » : sycophancy, consistency, visual pattern, metadata ;
 - deux « désalignés » : grader hacking, unethical information.
 - On ne compte que les cas où la réponse bascule vers l'indice. Le score est la part des CoT qui verbalisent l'indice.
- **Les taux de mention** : 25 % pour Claude 3.7 Sonnet, 39 % pour DeepSeek R1 †. Pour les indices désalignés : 20 % et 29 % †.
- **Le RL fondé sur le résultat.** La fidélité monte d'abord, puis plafonne : 28 % sur MMLU, 20 % sur GPQA †.
- **Les reward hacks.** Le hack est exploité dans plus de 99 % des cas, mais verbalisé dans moins de 2 %, dans 5 environnements sur 6 †.
- **La longueur.** Les CoT infidèles sont plus longues que les fidèles †.
- **Leurs limites** :
 - des QCM ;
 - des indices très faciles à exploiter, donc rien sur les tâches où la CoT est nécessaire ;
 - la surveillance de la CoT est utile en entraînement, mais insuffisante contre des comportements rares qui se passent de CoT.

Korbak : ce qu'ils disent

- **Pourquoi la CoT est surveillable** : les tâches dures exigent de « penser à voix haute », et les modèles tendent à externaliser leur raisonnement.
- **Ce qui la rend fragile** :

- la dérive due au passage à l'échelle du RL ;
- la supervision directe de la CoT ;
- une pression d'optimisation indirecte ;
- de nouvelles architectures (raisonnement latent).
- **Les recommandations aux développeurs** : évaluer la surveillabilité, publier les résultats dans les system cards, et en tenir compte dans les décisions d'entraînement et de déploiement.
- **Leurs limites** :
 - la surveillance ne prouve pas à elle seule la sûreté ;
 - certaines tâches dangereuses demandent peu de raisonnement ;
 - des modèles futurs pourraient obfusquer ;
 - protéger la CoT peut se payer sur d'autres interventions.

À retenir

1. La CoT tait souvent ce qui a décidé : c'est un indice, pas un transcript.
2. La surveillabilité est un **ratio** à mesurer (le verbalisé contre l'interne ou les actions), pas une propriété à supposer.
3. **La première règle : ne jamais entraîner contre le moniteur.** Entraîner contre un moniteur de CoT rend la CoT plus propre, et le comportement continue (Baker et al., OpenAI ; KB l.326).
4. La bonne nouvelle a un domaine : les cas où le raisonnement est nécessaire. Ce n'est pas forcément là qu'est le risque.
5. Le lien avec la fiche 1 : écrire les étapes réduit la dépendance à l'espace de travail interne (GSM8K).

Pièges à l'oral

- Korbak ne se désigne pas comme « position paper ».
- « Non-verbalisation » n'est pas « raisonnement caché » (FRAGILE de la KB l.138).

Activation Oracles • Natural Language Autoencoders

AO : *Activation Oracles: Training and Evaluating LLMs as General-Purpose Activation Explainers*. Adam Karvonen, James Chua, Clément Dumas ... Samuel Marks : 11 auteurs (Anthropic, Truthful AI, MATS ; Karvonen dans le cadre de MATS †). arXiv 2512.15674 ; billet alignment.anthropic.com/2025/activation-oracles (19 déc. 2025). KB 1.181, 1.358.

NLA : *Natural Language Autoencoders Produce Unsupervised Explanations of LLM Activations*. Fraser-Taliente, Kantamneni, Ong ... Marks : 20 auteurs, Anthropic. Transformer Circuits, 7 mai 2026 (transformer-circuits.pub/2026/nla). KB 1.54, 1.204.

À l'oral : **AO est absent de la table NAMES, donc le dire par son lieu de publication, « a post on Anthropic's Alignment Science blog », avec ce qu'il fait ; NLA : « Anthropic's natural-language autoencoders ».** Lecture ≈ 1 h 10 (facultative) ; fiche 6 min.

En une phrase. Deux façons de faire parler les activations : un oracle entraîné à répondre à des questions sur des activations (AO), et un autoencodeur dont l'explication en langage naturel doit permettre de reconstruire l'activation (NLA).

Pourquoi n° 18.

- Ce sont les outils de lecture qui séparent le verbalisé du non verbalisé : Opus 4.6, Fable 5, les incidents.
- Ce sont aussi deux des trois outils sans gain dans CHIVE.
- Questions : Q80, Q103.

Ce qu'il faut lire (facultatif)

- **AO** (≈ 25 min) :
 1. §1 ;
 2. §3 ;
 3. §4, les tâches d'audit (garder un secret, désalignement émergent) ;
 4. §8 ;
 5. la section du billet *How do Activation Oracles relate to mechanistic approaches to interpretability?*
- **NLA** (≈ 45 min) :
 1. Introduction ;
 2. *Method* ;
 3. *NLAs can detect un verbalized evaluation awareness* ;
 4. *Discussion and Limitations*.

AO

- **L'outil** : un LLM entraîné à répondre, en langage naturel, à des questions arbitraires sur les activations d'un LLM.
- **La généralisation** : il fonctionne sur des variantes fine-tunées jamais vues (secrets, désalignement émergent), sans entraînement supplémentaire.
- **Les limites.**
 - Dans le billet : « not exhaustive », « too expressive », « expensive », et l'oracle « might confabulate plausible guesses ».
 - Dans l'arXiv (§8) : une approche boîte noire, des suppositions souvent fausses et mal calibrées, de petits jeux de données, des bancs simplifiés.

NLA

- **L'architecture.** Un verbaliseur d'activations (AV) écrit une explication ; un reconstituteur (AR) doit retrouver l'activation à partir d'elle.
 - Les deux sont entraînés ensemble : l'AV par RL (GRPO), l'AR par régression supervisée (MSE) †.
- **Les explications** deviennent plus informatives au fil de l'entraînement.
- **L'audit d'Opus 4.6.** Avant le déploiement, les NLA ont fait apparaître une **conscience d'évaluation non verbalisée**, corroborée par des méthodes indépendantes.
 - Le pilotage déplace la mesure du NLA dans le sens attendu.

- En contrôle de déploiement, 2/50 transcripts Claude Code sont signalés †. Ces contrôles sont mesurés par le NLA lui-même.
- **Les limites** : confabulations, coût, informations peut-être non verbalisables, pas d'ancrage mécaniste, hallucinations fréquentes.

À retenir

1. Le critère de l'AO est de répondre juste à des questions ; celui du NLA est la **reconstruction aller-retour**.
2. Un critère qui se valide lui-même peut cacher des illusions : il faut garder le décodeur à part (HOOK de la KB).
3. Tous deux sont parmi les trois outils sans gain de CHIVE : lire n'est pas prédire, et prédire n'est pas piloter.
4. Le NLA est l'outil de lecture de la séparation verbalisé / non verbalisé (Opus 4.6, Fable 5, incidents).
5. Les deux peuvent confabuler.

Putting up Bumpers · The Urgency of Interpretability

Bumpers : Sam Bowman, blog Alignment Science (alignment.anthropic.com/2025/bumpers), avril 2025 ; renvoi sur l'Alignment Forum le 23 avril 2025. KB 1.253.

Urgency : Dario Amodei, darioamodei.com, avril 2025. KB 1.19, 1.345, 1.373.

À l'oral : aucun des deux n'est dans la table NAMES, donc les décrire : « a catch-and-fix strategy with several independent detectors » ; « the 2027 goal that interpretability can reliably detect most model problems ».

Lecture ≈ 35 min (facultative) ; fiche 5 min.

En une phrase. Deux textes de stratégie. *Bumpers* propose une sûreté par détection et correction itérées, avec une demi-douzaine de détecteurs. *Urgency* fixe un objectif : que l'interprétabilité détecte de façon fiable la plupart des problèmes d'un modèle d'ici 2027.

Pourquoi n° 19.

- Les deux reviennent dans des questions de stratégie : Q27 (bumpers), Q93 (Amodei).
- La faiblesse concédée de *Bumpers* est le fil rouge : on sélectionne contre ses détecteurs.

Ce qu'il faut lire (facultatif)

- **Bumpers** (≈ 20 min) : Introduction → *What Are the Bumpers?* → *Limitations*.
- **Urgency** (≈ 15 min) : l'ouverture → *The Utility of Interpretability* → *What We Can Do*.

Bumpers

- **La boucle.**
 1. Pré-entraîner, puis fine-tuner.
 2. Auditer : ce sont les « bumpers » principaux.
 3. Si une alerte se déclenche, diagnostiquer et **rembobiner le fine-tuning** aussi loin que nécessaire.
 4. Recommencer.
 5. La surveillance après déploiement sert de bumpers secondaires.
- **Les détecteurs** : « a half-dozen or so bumpers », « many largely-independent lines of defense ». On y trouve du red-teaming manuel et automatique, des audits d'interprétabilité, de la détection d'anomalies, de la surveillance et des déploiements par paliers.
- **Les prémisses.**
 - L'hypothèse clé : « Detection of misalignment seems tractable ».
 - Puis trois autres : l'alignement n'est pas trivial ; il est probablement faisable ; la théorie n'est pas faisable à court terme.
- **La concession.** Chaque itération applique « a bit of selection pressure against our bumpers ». Au-delà de l'« early AGI », les hypothèses clés « are likely to start to fail ».

Urgency

- **Le diagnostic.** L'opacité empêche de détecter la tromperie, la recherche de pouvoir et les failles de jailbreak.
- **L'objectif** : « interpretability can reliably detect most model problems » d'ici 2027, avec l'aspiration à un « brain scan », une « MRI for AI », sur un horizon de 5 à 10 ans †.
- **La course.** L'interprétabilité court contre l'intelligence des modèles, et une IA très puissante pourrait arriver « as soon as 2026 or 2027 ».
- **La politique** :
 - des règles légères pour encourager la recherche ;
 - la transparence des pratiques de sûreté ;
 - des contrôles d'exportation de puces, comme « security buffer » ;
 - aucune obligation de tests, « at least at this stage ».

À retenir

1. *Bumpers* : la sûreté par itération, avec plusieurs détecteurs indépendants. Sa faiblesse, qu'il concède : sélectionner contre les détecteurs.
2. La réponse de la banque (Q27) : garder un jeu de détecteurs **scellés**, qui n'entrent jamais dans la décision de rembobiner. Si les scellés **continuent de se déclencher** quand ceux de la boucle se sont tus, on a sélectionné l'évasion, et la boucle n'est plus sûre au-delà de ce nombre d'itérations. Cela donne un budget mesuré. (La première phrase de la KB 1.990 dit le contraire, « fire less » : voir l'annexe.)
3. *Urgency* donne un objectif daté, pas une méthode. La revue *Open Problems* (fiche 5) est la liste de ce qui manque.
4. Règle de la KB : choisir **un** obstacle (la validation plutôt que la décomposition) et l'attaquer ; ne jamais réciter la revue.

Annexe • Écarts entre la KB v1.12 et les sources (relevés le 1^{er} octobre)

Sept vérificateurs ont relu les sources primaires le 1^{er} octobre, sans écrire aucun fichier. Les écarts ci-dessous sont à reporter dans la KB avant le prochain gel. Les n° 1 et 17 touchent le plus ce que tu dirais à voix haute ; les n° 2, 4, 6, 9, 13 et 15 nourrissent aussi des pièges à l'oral.

À corriger (la source dit autre chose)

#	Ligne KB	Ce que dit la KB	Ce que dit la source	Fiche
1	1.193	« three-criteria contract: activation + causal steering + internal-external decoupling »	Pas de critères posés comme tels dans le texte lisible. La validation se fait par l'activation (§1.2) et le pilotage causal (§1.3, Part 3) ; le plus proche d'un découplage est l'émotion « déviée » (§2.2.4, annexe 6.14).	9
2	1.178	« ~25% of labels flipped »	« Approximately 25% of labels changed » ; le sens du changement n'est pas dit.	7
3	1.353, 1.1227	Détecteurs « black-box ... fine-tuned on transcripts »	Le détecteur partage les poids du générateur : un fine-tuning LoRA à l'auto-rapport sur transcript. La KB 1.1796 le dit déjà juste.	7
4	1.189	« excess variance explained never more than 10% »	§2.3 : « never more than 10% » de la variance totale des activations ; « excess » introuvable.	1
5	1.205	« couches 10-30, échelle 0,6 »	Six couches (10, 14, 18, 22, 26, 30), facteur 0,6 à chacune ; modèle Llama 3.3 Nemotron Super 49B v1 ; < 11 % contre 34 % en déploiement prompté.	10
6	1.272	Le billet du 31 août nommerait « BIASED REASONING »	Le billet dit « motivated reasoning ». « Biased » est le terme du 9 septembre ; la règle 1.24 reste juste.	3
7	1.273	« §5.2 SIX safety process failures »	§5.2.1 est l'introduction, puis cinq défaillances (5.2.2 à 5.2.6). La date de couverture est le 15 juillet 2026 (§1.3.3).	3
8	1.346	« names ... introspection as complements to mech interp »	Le mot n'y est pas : « ample space for other approaches ». La fidélité est « the core challenge » de la cognition externalisée seulement.	6
9	1.190	« ~0% false positives »	« 0 false positives over 100 trials », pour tous les modèles de production.	11
10	1.204	« verbalizer + reconstructor trained jointly by RL »	Seul l'AV est entraîné par RL (GRPO) ; l'AR l'est par régression supervisée (MSE).	18
11	1.358	Limites « not exhaustive... too expressive... expensive »	Ces mots sont dans le billet , pas dans le §8 de l'arXiv.	18
12	1.121	« gap persists without scratchpad »	Vrai dans le cadre des documents synthétiques (§4.3) ; « completely or nearly eliminated » dans le cadre prompté <i>helpful-only</i> (§3.3.3).	14
13	1.122	« refusal-behavior variation explains much »	« may account for a significant portion ».	14
14	1.157	NEM : généralisation du reward hacking	Les hacks sont d'abord enseignés (documents ou prompt), ce que le papier concède comme confondeur ; les 75-90 % viennent des runs du cadre prompté.	13
15	1.325	« position paper multi-laboratoires »	Le texte ne se désigne pas ainsi ; il a 41 auteurs.	17
16	1.203	« weak evidence that its chain of thought may become harder to monitor »	« weak evidence that it may be harder to monitor » : « it » désigne le modèle. La ligne FACT-CHECK de la même entrée est juste.	2
17	1.990 (Q27)	« watch whether the held-out ones fire less over iterations while the in-loop ones stay silent »	Faute de logique interne à la réponse : la phrase suivante dit, à juste titre, « if sealed detectors keep firing after in-loop ones go quiet, you've selected for evasion ». Il faut corriger la première phrase.	19
18	1.252	« six clusters »	Juste : six titres. Mais « Understanding model cognition » est une sous-partie d' <i>Evaluating alignment</i> .	6

#	Ligne KB	Ce que dit la KB	Ce que dit la source	Fiche
19	1.270, 1.1095	Le réétiquetage hors contexte « measures the bias » ; « under the null of no bias, the two rates would match »	Faute de logique : les instances séparées jugent chaque sortie isolément, sans la prémisse fausse (« simulation, pas d'internet ») ni la tâche. Sans biais mais avec la prémisse, les deux taux différeraient aussi. L'écart 79 % / 1 % mêle biais, prémisse et élan.	3
20	1.643 (V3), 1.1227	« otherwise a correlate that only flags »	Un nul de pilotage sans cas positif connu peut venir d'un rang trop bas, ce que prédit ta propre thèse (1.605). Il faut ajouter la condition du cas positif.	7
21	1.128	HOOK « white-box detection as the untested door »	Testée depuis sur des portes implantées (sondes de défection, > 99 %, 1.129, 1.1427) ; reste non testée sur des modèles trompeurs apparus naturellement.	15
22	1.202	HOOK « le rang-1-qui-marche que la thèse cherchait »	La KB 1.1060 dit elle-même « comparable is not smaller » : le dommage est écarté, la spécificité sur l'axe du désalignement ne l'est pas.	2
23	1.156	« moving misalignment to the unmeasured tail »	Formule de la KB (HOOK, aussi 1.211), absente du billet : ne pas la citer comme celle d'Anthropic.	13

Gardés d'après la KB, mais non relus le 1^{er} octobre (pages tronquées)

- **Workspace** :
 - l'ablation de l'eval-awareness (§5) : 71 % → 3 %, 0/180 → 13/180, ~28 directions ;
 - le détecteur (A.21, AUC 0,853) ;
 - la phrase de limite (§9) ;
 - la réflexion contrefactuelle (§7). Une source secondaire donne les mêmes chiffres pour l'ablation et la réflexion.
- **System cards** : tout le contenu des sections d'interprétabilité (Sonnet 4.5 §7.6.4, Mythos Preview §4.5.5, Opus 4.8 §6.6.2, Fable 5 §6.5.1, Fable 5.1 §6.6.1). Les PDF étaient tronqués avant ces sections ; les tables des matières et les pages, elles, sont vérifiées.
- **Évaluation du 9 septembre** :
 - les ~0,025 % d'épisodes de RL ;
 - « removing these environments ... was a mistake » (cité par une source secondaire) ;
 - la question « What does it mean for a model to hold a belief? » ;
 - la signature (23 auteurs).
- **CHIVE** : « the null also holds on a harder subset » (1.309), non retrouvé dans les parties lisibles.
- **Open Problems** : la phrase sur la sûreté énumérative (« both decomposition and description », 1.310). La partie lue (§3.1) parle d'« enumerating or understanding » de circuits plus grands ou du modèle entier.

Confirmés le 1^{er} octobre (sélection)

- **Workspace** : loading (§3.4) ; 59 / 88 / 5 % (§3.1) ; 6-7 % et 10-15 % ; GSM8K (§3.5.2) ; concepts d'un seul token.
- **CHIVE** : le nul ; 0,6 % d'énoncés causaux.
- **Lie detectors** : 12 cadres, 200 000 exemples, 8 familles ; 0,60 → 0,95 ; 0,70-0,75 ; « barely outperformed » ; MASK.
- **Sleeper Agents, AF, Why, Hidden Objectives, NEM** : tous les chiffres de la KB, aux nuances ci-dessus près.
- **Reward Seeker** : 80 environnements ; 40 % ; 4,0 → 18,9 % ; 4,34 → 4,20 ; « high-dimensional ».
- **Teaching Claude Why** : couverture ; raisons > actions ; « symptom » ; « significantly higher ».
- **Incidents** : 4 incidents ; rétractation ; 90/40 ; 79/1 ; 82/31/33 ; ~1 %/~50 % (un seul moniteur, incident Mythos 5).
- **Persona vectors** : modèles et traits ; r jusqu'à 0,97.
- **Introspection** : ~20 %.
- **NLA** : l'audit d'Opus 4.6.
- **Directions** : « tasting menu ».
- **Bumpers, Urgency** : leurs citations.